عملی کورس · ایڈیشن 1.0 · نومبر 2026

AI ہوم لیب کو کم بجٹ میں چلانا

ذاتی لیپ ٹاپ یا پرانے ڈیسک ٹاپ سے ایک مقامی اسٹوڈیو تک، جو اسکرپٹ، آواز، تصاویر، ویڈیو اور ایڈیٹنگ کے لیے ہو۔ یوٹیوب پروڈکشن کے لیے بنایا گیا۔

یہ کورس سادہ اردو میں لکھا گیا ہے، ان لوگوں کے لیے جنہیں کمپیوٹر کی بنیادی معلومات ہیں۔ باب 1 سے 13 تک مکمل کرنے کے لیے پروگرامنگ کا تجربہ ضروری نہیں۔ ماڈلز کے نام، قیمتیں اور سافٹ ویئر ورژن تیزی سے بدلتے ہیں۔ کورس میں دیے گئے ہر نام کو مثال سمجھیں اور خریدنے یا انسٹال کرنے کے دن اسے دوبارہ جانچ لیں۔
انگریزی ترجمہ اصل ماخذ ہے۔ کمانڈز، کوڈ اور ڈایاگرام کے لیبل درستگی کے لیے انگریزی میں رکھے گئے ہیں۔

فہرست

باب 1 · تعارف: مقامی AI اسٹوڈیو کیوں، اور ویڈیو کیسے بنتی ہے

باب 2 · ہارڈ ویئر: AI کے کام میں اصل کیا اہم ہے

باب 3 · بجٹ کے مطابق مشین کا انتخاب

باب 4 · آپریٹنگ سسٹم: Windows، Linux یا macOS

باب 5 · سسٹم تیار کرنا، قدم بہ قدم

باب 6 · بنیادی AI اسٹیک انسٹال کرنا اور پہلی گفتگو

باب 7 · LLM ماڈلز کا انتخاب

باب 8 · گہری سوچ، کوڈنگ اور اسکرپٹس کے لیے LLMs

باب 9 · تصویر سازی (Image Generation)

باب 10 · بیانیہ اور آواز (Text-to-Speech، Speech-to-Text)

باب 11 · ویڈیو سازی: بجٹ میں کیا ممکن ہے

باب 12 · ویڈیو ایڈیٹنگ اور آخری ایکسپورٹ

باب 13 · یوٹیوب پروڈکشن لائن کو خودکار بنانا

باب 14 · ہارڈ ویئر کی حدیں، خرابیوں کا حل اور کارکردگی

باب 15 · کیریئر کا راستہ، بجٹ کا منصوبہ اور 12 ہفتے کا مطالعاتی منصوبہ

ضمیمہ A · کمانڈ کی فہرست

ضمیمہ B · اصطلاحات کی فرہنگ

ضمیمہ C · لائسنس کا مختصر حوالہ

باب 1

تعارف: مقامی AI اسٹوڈیو کیوں، اور ویڈیو کیسے بنتی ہے

1.1 یہ کورس کس کے لیے ہے

یہ کورس دکھاتا ہے کہ ایک عام لیپ ٹاپ یا پرانے ڈیسک ٹاپ کو نجی AI ورک اسٹیشن میں کیسے بدلا جائے۔ یہ مشین اسکرپٹ لکھ سکے گی، زبان کے ماڈل کے ساتھ متن پڑھ اور لکھ سکے گی، آواز میں بیانیہ (وائس اوور) بنا سکے گی، تھمب نیل اور خاکے بنا سکے گی، مختصر ویڈیو کلپس تیار کر سکے گی، اور حتمی ویڈیو کی ایڈیٹنگ میں مدد کرے گی۔ یہ سب کام آپ ہر درخواست کی الگ قیمت دیے بغیر کریں گے، اور اپنا غیر شائع شدہ کام کسی کلاؤڈ سروس کو بھیجے بغیر۔

یہ کورس ایک عام شخص کے لیے لکھا گیا ہے جسے کمپیوٹر کی بنیادی معلومات ہوں: آپ پروگرام انسٹال کر سکتے ہوں، فائلیں کاپی کر سکتے ہوں، اور ہدایت ملنے پر ٹرمینل کھول سکتے ہوں۔ کسی پروگرامنگ ڈگری کی ضرورت نہیں۔ جہاں کمانڈ آئے گی، اس کی وضاحت ساتھ ہوگی اور آپ اسے ہو بہو نقل کر سکتے ہیں۔

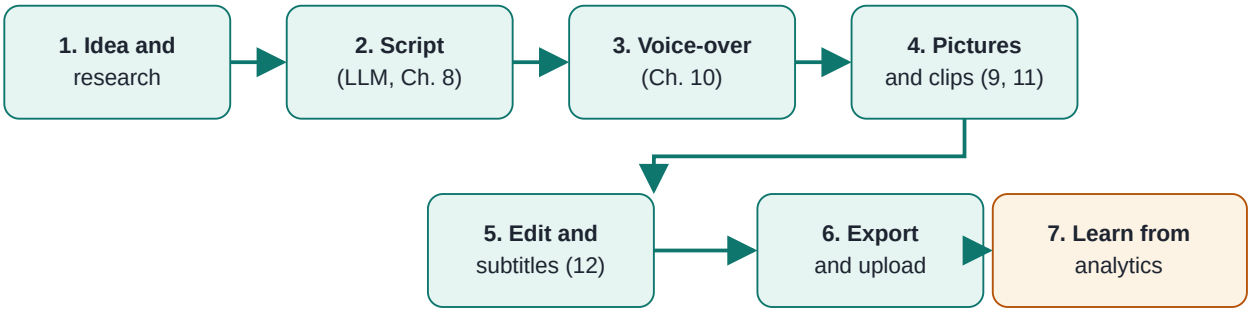
1.2 مقامی AI کیوں چلائیں؟

- **لاگت پر قابو۔** کلاؤڈ سبسکرپشن ماہانہ یا فی درخواست پیسے لیتی ہے۔ مقامی ماڈل کی لاگت صرف بجلی ہے، اور مشین خریدنے کے بعد ہر اضافی اسکرپٹ یا تصویر مفت ہے۔
- **رازداری۔** آپ کے ڈرافٹ، کلائنٹ کا مواد اور چینل کے غیر اعلان شدہ منصوبے آپ کی ڈسک پر رہتے ہیں۔
- **کوٹے کا انتظار نہیں۔** آپ اتوار کی رات ہزار تجربات کر سکتے ہیں اور روزانہ کی حد نہیں لگتی۔
- **سیکھنا۔** ٹولز خود چلانے سے آپ سمجھتے ہیں کہ ماڈل کیسے رویہ دکھاتے ہیں، اور یہ ہنر آج کے کلائنٹس اور آجروں کو درکار ہے۔

مقامی AI کی کچھ کمزوریاں بھی ہیں، جن پر باب 14 میں کھل کر بات ہوگی۔ سب سے طاقتور ماڈل بجٹ مشین میں نہیں سمائیں گے، اور ویڈیو سازی سست ہے۔ ایک اچھا اسٹوڈیو مقامی ٹولز کو کبھی کبھار کلاؤڈ کے ساتھ ملا کر استعمال کرتا ہے۔ اس کورس کا مقصد یہ ہے کہ آپ کے بجٹ کے اندر مقامی حصہ جتنا مضبوط ہو سکتا ہے، بنایا جائے۔

1.3 یوٹیوب پروڈکشن لائن ایک تصویر میں

تقریباً ہر یوٹیوب ویڈیو، خاص طور پر وہ جو چہرے کے بغیر بنتی ہے، ایک ہی سلسلے کے مراحل سے گزرتی ہے۔ اس کورس کا ہر حصہ اس سلسلے کے کسی ایک مرحلے سے جڑا ہے، اس لیے یہ تصویر ذہن میں رکھیں۔



Every box can run on your homelab. Human checks (fact, tone, rights) sit between the boxes.

شکل 1.1 ویڈیو کے سات مراحل۔ کورس میں ہر ایک کو سمجھایا گیا ہے۔ (ڈایاگرام کے لیبل انگریزی میں ہیں)

1.4 آپ کا ہوم لیب کیا کر سکے گا اور کیا نہیں

کام	بجٹ مشین پر حقیقت پسندانہ؟	تبصرہ
اسکرپٹ، خاکے، عنوان، تفصیل	ہاں، بہت اچھی طرح	چھوٹے اور درمیانے زبان کے ماڈل کافی ہیں، اگر ہدایات واضح ہوں۔
اپنے ڈرافٹ کے حقائق کی جانچ	کچھ حد تک	مقامی ماڈل اہم نکات چھوڑ سکتے ہیں۔ ضروری دعوے خود تصدیق کریں۔
وائس اوور بیانیہ	ہاں	جدید اوپن ٹیکسٹ ٹو اسپیچ CPU پر بھی چلتا ہے۔ معیار اچھا ہے، اسٹوڈیو جیسا کامل نہیں۔
تصاویر اور تھمب نیل	ہاں، 8 GB یا زیادہ GPU کے ساتھ	کمزور ہارڈ ویئر پر سست۔ تصویر کے اندر متن اب بھی غیر معتبر ہے۔
مختصر AI ویڈیو کلپس (3 سے 6 سیکنڈ)	صرف 12 GB+ GPU کے ساتھ، اور آہستہ	فی کلپ منٹوں سے لے کر کئی دس منٹ لگ سکتے ہیں۔ انہیں B-roll کے طور پر استعمال کریں، پوری ویڈیو کے طور پر نہیں۔
ایڈیٹنگ، سب ٹائٹلز، ایکسپورٹ	ہاں	ایڈیٹنگ میں AI کم درکار ہے۔ اصل رکاوٹ عموماً آپ کا اپنا وقت ہوتا ہے۔
طویل فیچر لینتھ ویڈیو	نہیں	کسی بھی بجٹ ہارڈ ویئر پر عملی نہیں۔

1.5 یہ کورس کیسے ترتیب دیا گیا ہے

باب 2 سے 5 آپ کو تیار کرتے ہیں: آپ سیکھتے ہیں کون سا ہارڈ ویئر اہم ہے، مشین کا انتخاب، آپریٹنگ سسٹم کا فیصلہ اور اس کی ترتیب۔ باب 6 سافٹ ویئر انسٹال کرتا ہے۔ باب 7 سے 12 ہر صلاحیت کو الگ الگ سمجھاتے ہیں۔ باب 13 انہیں ایک دہرائے جانے والے پروڈکشن سلسلے میں جوڑتا ہے۔ باب 14 حدود اور مسائل سے نمٹتا ہے۔ باب 15 کیریئر کا راستہ اور 12 ہفتے کا منصوبہ دیتا ہے۔ ضمیموں میں کمانڈ کی فہرست، اصطلاحات کی فرہنگ اور لائسنس کا حوالہ ہے۔

مشورہ

باب 1 سے 6 ترتیب سے پڑھیں، چاہے آپ کے پاس پہلے سے کمپیوٹر ہو۔ گھریلو AI کی زیادہ تر ناکام ترتیبیں AI میں نہیں، بلکہ تیاری کے مرحلے میں خراب ہوتی ہیں۔

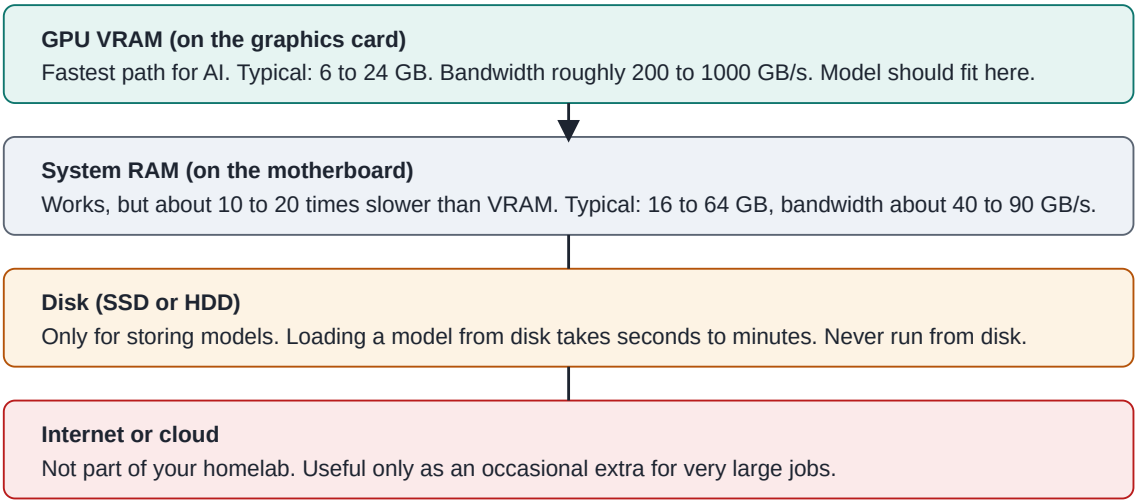
ہارڈ ویئر: AI کے کام میں اصل کیا اہم ہے

2.1 پانچ حصے جو طے کرتے ہیں کہ آپ کیا کر سکتے ہیں

1. **گرافکس میموری (VRAM)** گرافکس کارڈ پر۔ تصاویر، ویڈیو اور تیز LLM کے لیے یہ سب سے اہم عدد ہے۔
2. **سسٹم میموری (RAM)**۔ اس میں آپریٹنگ سسٹم، ایڈیٹنگ سافٹ ویئر اور وہ ماڈل رہتے ہیں جو VRAM میں نہیں سماتے۔
3. **گرافکس پروسیسر (GPU)**۔ اس کی رفتار اہم ہے، مگر تب جب VRAM کافی ہو۔
4. **سینٹرل پروسیسر (CPU)**۔ ایڈیٹنگ، ڈی کوڈنگ اور وہ ماڈل جو GPU کے بغیر چلتے ہیں، ان کے لیے اہم ہے۔
5. **اسٹوریج**۔ ماڈل چند گیگا بائٹ سے لے کر 100 GB سے زیادہ تک کے ہوتے ہیں۔ تیز SSD لوڈنگ کی رفتار بھی بڑھاتا ہے۔

2.2 ماڈل کہاں رہتا ہے: میموری کی سیڑھی

AI ماڈل نمبروں کی ایک بڑی فائل ہے۔ جواب تیزی سے دینے کے لیے کمپیوٹر کو ان نمبروں کو ایک سیکنڈ میں کئی بار پڑھنا ہوتا ہے۔ جتنے قریب یہ نمبر پروسیسر کے ہوں اور جتنا تیز راستہ ہو، جواب اتنا ہی جلدی آتا ہے۔



شکل 2.1 میموری کی سیڑھی۔ رفتار نیچے کی طرف گھٹتی ہے۔ کام کرنے والا ماڈل VRAM میں رکھیں۔ (ڈایاگرام کے لیبل انگریزی میں ہیں)

2.3 VRAM سب سے اہم عدد کیوں ہے

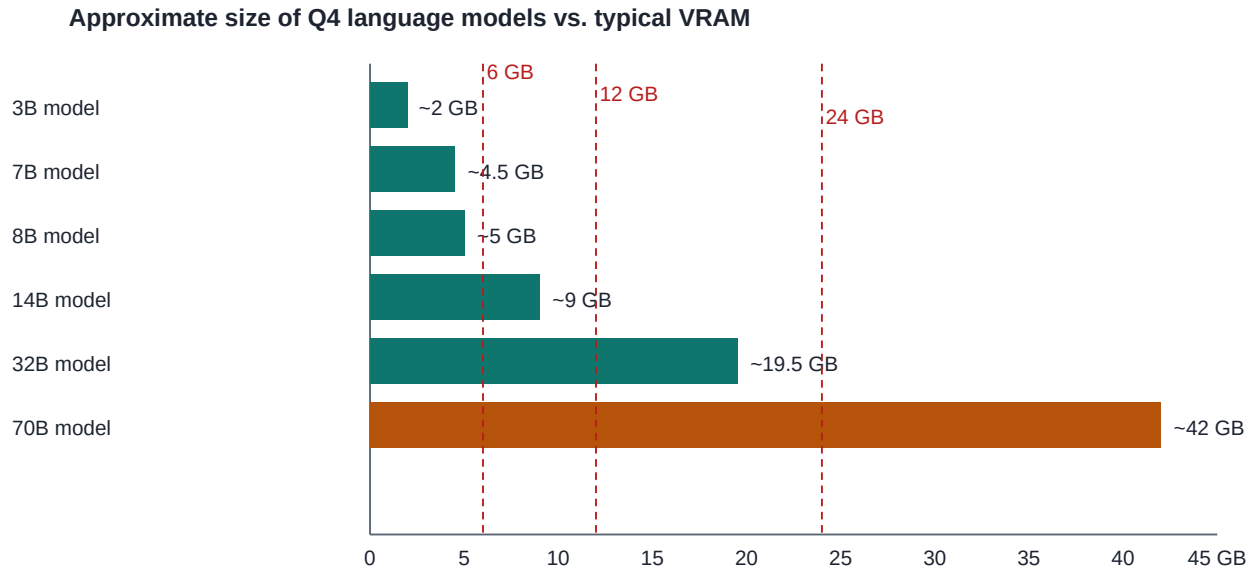
وہ لینگوئج ماڈل جو گرافکس کارڈ کے اندر پورا سما جائے، آرام دہ رفتار سے جواب دیتا ہے۔ اگر اس کا کچھ حصہ سسٹم RAM میں جائے تو جواب کافی سست ہو جاتا ہے۔ اگر بالکل نہ سمائے تو پروگرام یا تو شروع ہی نہیں ہوتا یا "out of memory" کا پیغام دے کر بند ہو جاتا ہے۔ تصویر اور ویڈیو ماڈل بھی یہی رویہ دکھاتے ہیں: انہیں اپنے وزن کے ساتھ ہر مرحلے کے لیے اضافی جگہ چاہیے۔

میموری کا اندازہ لگانے کا سادہ اصول

لینگوئج ماڈل کے لیے جو فی وزن تقریباً 4 بٹس تک سکڑا ہوا ہو (سب سے عام فارمیٹ، جسے Q4 کہا جاتا ہے)، فائل کا سائز تقریباً یوں ہوتا ہے:

```
file size (GB) ≈ number of parameters (billions) × 0.6

  7B model   → about 4.5 GB
  8B model   → about 5 GB
  14B model  → about 9 GB
  32B model  → about 19 to 20 GB
  70B model  → about 42 GB
```



شکل 2.2 Q4 لینگوئج ماڈلز کا سائز بمقابلہ عام VRAM۔ سبز = 12 GB یا 24 GB کارڈ میں سما جاتا ہے، نارنجی = 48 GB کارڈ یا بھاری آف لوڈنگ درکار ہے۔ جتنی VRAM کی لکیریں ہیں وہ عام سائز ہیں۔ سائز تقریباً ہیں۔ (ڈایاگرام کے لیبل انگریزی میں ہیں)

ماڈل کے وزن کے علاوہ، ماڈل کو گفتگو کے لیے بھی میموری چاہیے (جسے *context* کہتے ہیں)۔ لمبے context پر ایک سے کئی گیگا بائٹ تک اضافی جگہ لگ سکتی ہے۔ ایک معقول ہدف یہ ہے کہ گرافکس کارڈ پر 1 سے 2 GB خالی چھوڑیں۔

2.4 رفتار: چپ کے نام سے زیادہ میموری بینڈوتھ کیوں اہم ہے

جب لینگوئج ماڈل متن لکھتا ہے تو ہر نئے لفظ (token) کے لیے تقریباً اپنے سارے وزن پڑھتا ہے۔ اس لیے رفتار تقریباً اس بات سے طے ہوتی ہے کہ میموری کتنی تیزی سے پڑھی جا سکتی ہے۔ ایک سادہ اندازہ:

```
tokens per second  ≈  memory bandwidth (GB/s)  ÷  model file size (GB)

Example: 7B model at 4.5 GB on a graphics card with 360 GB/s
         ≈ 80 tokens/s theoretical (real results are lower, often 40 to 60)

Example: same model on dual-channel DDR4 RAM at 50 GB/s
         ≈ 11 tokens/s theoretical (real results often 4 to 8)
```

انسان کی پڑھنے کی رفتار تقریباً 5 سے 8 الفاظ فی سیکنڈ ہے۔ چیٹ میں 10 tokens فی سیکنڈ سے اوپر کی رفتار تیز محسوس ہوتی ہے۔ 3 tokens فی سیکنڈ سے کم پر ٹول انٹرایکٹو کام کے لیے تنگ کرنے لگتا ہے، البتہ رات کی بیچ جاب کے لیے پھر بھی قابلِ قبول ہے۔

2.5 دوسرے حصے، مختصراً

حصہ	اس کورس کے لیے کم از کم	تجویز کردہ	کیوں
سسٹم RAM	16 GB	32 GB	ویڈیو ایڈیٹنگ، براؤزر کے ٹیبز اور AI ٹولز سب RAM کے لیے لڑتے ہیں۔ swap صرف تھوڑی مدد کرتا ہے۔
گرافکس کارڈ VRAM	6 GB (صرف سیکھنے کے لیے)	12 GB یا 16 GB	طے کرتا ہے کہ کون سے تصویر، ویڈیو اور LLM ماڈل سمائیں گے۔
CPU	4 کور، 2015 یا بعد کا	6 سے 8 جدید کور	ایڈیٹنگ، سب ٹائٹلز اور CPU پر چلنے والے ماڈلز کے لیے۔
اسٹوریج	256 GB SSD جس میں 100 GB خالی ہو	1 TB NVMe SSD	ایک تصویری ماڈل 2 سے 7 GB کا، ایک ویڈیو ماڈل 5 سے 30 GB کا، اور ویڈیو پروجیکٹس بڑے ہوتے ہیں۔
پاور سپلائی (ڈیسک ٹاپ)	450 W کا معیاری یونٹ	550 سے 750 W	لوڈ کے تحت گرافکس کارڈ زیادہ تر بجلی اسی سے لیتا ہے۔ سستے یونٹ کریش کا سبب بنتے ہیں۔
کولنگ	چلتے ہوئے پنکھے، صاف فلٹر	اچھا ہوا کا بہاؤ اور کیس میں جگہ	گرمی سے رفتار کم ہوتی ہے (throttling) اور شور بڑھتا ہے۔
نیٹ ورک	Wi-Fi یا ایتھرنیٹ	گیگابٹ ایتھرنیٹ	ماڈل ڈاؤن لوڈ کرنے کے لیے (ہر ایک اکثر 5 سے 30 GB) اور دوسرے آلات سے مشین تک پہنچنے کے لیے۔

لیپ ٹاپ کے بارے میں انتباہ

لیپ ٹاپ کا گرافکس چپ اکثر اسی نام کے ڈیسک ٹاپ کارڈ سے کمزور ہوتا ہے، اور گرم ہونے پر رفتار کم کر دیتا ہے۔ اس کی اسپیک شیٹ میں GPU VRAM اور "maximum graphics power" (TGP) دیکھیں۔ 8 GB VRAM والا لیپ ٹاپ قابلِ استعمال ہے۔ 4 GB والا یا صرف انٹیگریٹڈ گرافکس والا لیپ ٹاپ سیکھنے کے لیے ٹھیک ہے، پروڈکشن کے لیے نہیں۔

باب 3

بجٹ کے مطابق مشین کا انتخاب

3.1 چار حقیقت پسندانہ درجے

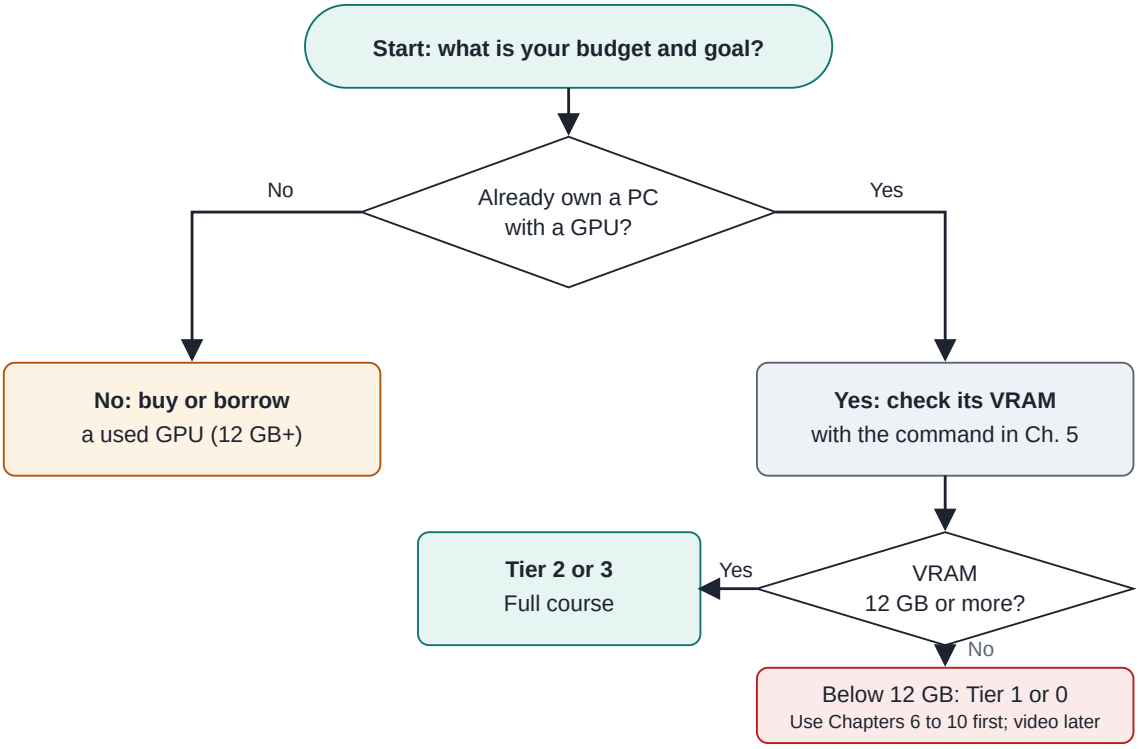
قیمتیں ہر ماہ بدلتی ہیں، اور استعمال شدہ (used) مارکیٹ ہر ملک میں مختلف ہوتی ہے۔ نیچے کے درجے بتاتے ہیں کہ کس قسم کی مشین ڈھونڈنی ہے، پھر موجودہ مقامی قیمتیں چیک کریں۔ "اچھا"، "قابلِ استعمال" اور "عملی نہیں" کے الفاظ اس بات کا اظہار ہیں کہ اس کورس کے مطابق استعمال کرنے پر مشین سے کیا توقع رکھیں۔

درجہ	عام مشین	کیا اچھا کرتی ہے	کیا اچھا نہیں کرتی
0. سیکھنا	لیپ ٹاپ یا ڈیسک ٹاپ، 8 GB RAM، کوئی الگ GPU نہیں (صرف انٹیگریٹڈ گرافکس)	CPU پر 1 سے 3 ارب پیرامیٹر والے ماڈلز کے ساتھ چیٹ، اسکرپٹ، منصوبہ بندی، پراکسی فائلوں کے ساتھ بنیادی ایڈیٹنگ، تمام ٹولز سیکھنا	تصاویر (بہت سست)، کوئی بھی ویڈیو سازی، بڑے ماڈلز
1. انٹری لیول	16 تا 32 GB RAM والا ڈیسک ٹاپ اور استعمال شدہ NVIDIA کارڈ جس میں 6 تا 8 GB VRAM ہو (مثلاً GTX 1660، RTX 2060، RTX 3050 Super)	7 تا 8 ارب پیرامیٹر والے ماڈل اچھی رفتار سے، وائس اوور، SDXL طرز کی تصاویر چند دس سیکنڈ میں، ایڈیٹنگ	14B سے بڑے LLM (سست)، بہت چھوٹے کلپس سے آگے ویڈیو سازی
2. مثالی درجہ	32 GB RAM والا ڈیسک ٹاپ اور استعمال شدہ NVIDIA کارڈ جس میں 12 GB VRAM ہو (مثلاً RTX 3060 12 GB)، یا 16 GB VRAM (مثلاً RTX 4060 Ti 16 GB)	14 ارب پیرامیٹر والے ماڈل اچھی رفتار سے، جدید تصویری ماڈلز، چھوٹے ویڈیو ماڈلز، Full-HD ایڈیٹنگ	سب سے بڑے reasoning ماڈلز، لمبی اعلیٰ ریزولیوشن ویڈیو
3. بھاری	استعمال شدہ NVIDIA RTX 3090 یا 4090 (24 GB VRAM)، یا 32 GB+ RAM والی ورک اسٹیشن	32 ارب پیرامیٹر والے ماڈل، تیز تر تصویری اور ویڈیو کام، 4K ایڈیٹنگ	پھر بھی کلاؤڈ GPU فارمز کے برابر نہیں، اور بجلی کا بل اور شور زیادہ ہیں

3.2 Apple Silicon اور دوسرے آپشنز

Apple Silicon میک (M1 اور بعد کے) پروسیسر اور گرافکس کے درمیان ایک ہی میموری کا تالاب شیئر کرتے ہیں۔ 16 یا 32 GB unified memory والا میک Ollama اور LM Studio جیسے ٹولز کے ذریعے LLM اچھی طرح چلاتا ہے۔ تصویری کام کے لیے خاص میک کے لیے بہتر کیے گئے ٹولز موجود ہیں، مگر عموماً وہی میموری والے NVIDIA کارڈ سے سست ہوتے ہیں۔ ویڈیو سازی بھی میک پر عموماً سست ہے۔ AMD اور Intel کارڈ کچھ ٹولز کے ساتھ چلتے ہیں، مگر سپورٹ کم مکمل ہے؛ اس کورس کے لیے NVIDIA محفوظ ترین انتخاب ہے۔

3.3 مشین کے انتخاب کا فیصلہ چارٹ



شکل 3.1 اپنا نقطۂ آغاز چننے کا سادہ چارٹ۔ مکمل ویڈیو کام کے لیے ہدف درجہ 2 یا 3 ہے۔ (ڈایاگرام کے لیبل انگریزی میں ہیں)

3.4 استعمال شدہ مشین خریدنے سے پہلے کیا دیکھیں

- **گرافکس کارڈ:** بیچنے والے یا پروڈکٹ پیج سے درست ماڈل اور VRAM کی تصدیق کریں۔ کارڈ پر لگے لیبل کی تصویر مانگیں۔ مائننگ کی تاریخ کے بارے میں سوال کریں اور پنکھوں اور حرارت کے نشانات دیکھیں۔
- **بجلی:** RTX 3060 جیسے کارڈ کو 550 W یا اس سے بہتر پاور سپلائی اور درست کنیکٹرز چاہیے۔ پاور سپلائی پر لکھی ریٹنگ دیکھیں۔
- **کیس اور فٹنگ:** کارڈ کی لمبائی کیس کے مطابق ناپیں۔ جدید کارڈ اکثر 25 cm یا اس سے لمبے ہوتے ہیں۔
- **میموری:** کم از کم 16 GB خریدیں، یا 32 GB کے لیے دو 16 GB کی سٹکس۔ مدر بورڈ کی زیادہ سے زیادہ سپورٹڈ RAM چیک کریں۔
- **اسٹوریج:** اگر خالی سلاٹ ہو تو 1 TB NVMe SSD شامل کریں۔ ماڈلز ڈسک جلدی بھر دیتے ہیں۔
- **ادائیگی سے پہلے جانچیں:** جہاں ممکن ہو، کارڈ لگا کر اسٹریس ٹیسٹ یا باب 5 کی کمانڈز چلائیں۔

> **بجٹ کا خیال**
>
> بہت سے لوگوں کے پاس پہلے سے گیمنگ PC یا NVIDIA کارڈ والا لیپ ٹاپ ہوتا ہے۔ جو آپ کے پاس ہے اسی سے شروع کریں۔ اپ گریڈ تب کریں جب باب 14 میں بتایا گیا طریقہ اصل رکاوٹ دکھا دے۔

باب 4

آپریٹنگ سسٹم: Linux، Windows یا macOS

4.1 مختصر جواب

اس کورس کے ٹولز کے لیے بہترین امتزاج یہ ہیں:

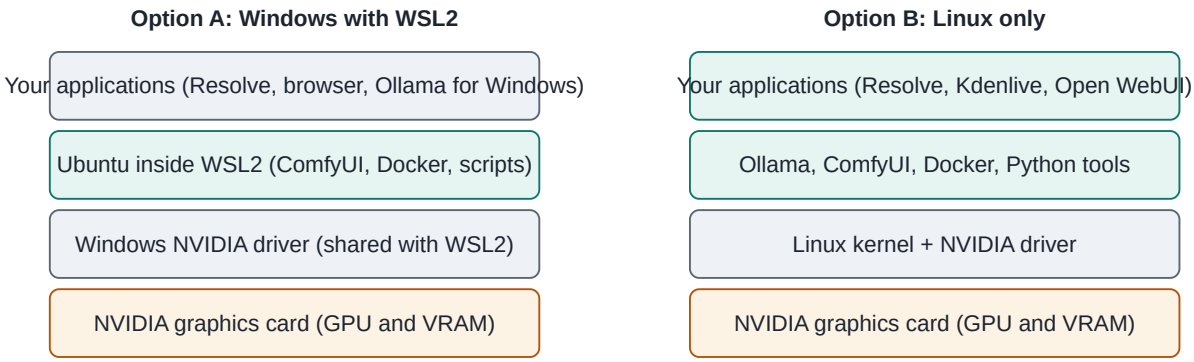
- **آسان آغاز، Windows استعمال کرنے والے:** Windows 11 کے ساتھ NVIDIA ڈرائیور، اور Ollama اور LM Studio براہِ راست Windows پر انسٹال۔ (Ubuntu) *WSL2* صرف تب شامل کریں جب کوئی ٹول Linux مانگے۔
- **ایک مخصوص AI مشین کے لیے سب سے قابلِ اعتماد:** Ubuntu 24.04 LTS (ڈیسک ٹاپ یا سرور) اور Ubuntu driver ٹول سے NVIDIA ڈرائیور۔
- **دوستانہ Linux ڈیسک ٹاپ:** Linux Mint 22 یا Pop!_OS (جو NVIDIA کارڈز کے ساتھ خاص طور پر اچھا ہے)۔
- **میک استعمال کرنے والے:** macOS پر Ollama، LM Studio اور DaVinci Resolve۔ تصویری ٹولز NVIDIA کے مقابلے میں سست ہیں۔

4.2 Windows بمقابلہ Linux

سوال	Windows 11	Linux (Ubuntu / Mint / Pop!_OS)
سیٹ اپ کی محنت	کم۔ تقریباً ہر ٹول کا انسٹالر موجود۔	درمیانی۔ کچھ ٹولز کے لیے ٹرمینل اور چند کمانڈز درکار۔
NVIDIA ڈرائیور	خودکار یا NVIDIA کی ویب سائٹ سے۔	Ubuntu پر ایک کمانڈ (`ubuntu-drivers`)؛ Pop!_OS کا خاص NVIDIA ISO۔
تصویری ٹولز (ComfyUI، Forge)	بہترین؛ بہت سے ایک کلک والے پیکج۔	بہترین؛ اکثر بھاری کاموں کے لیے ذرا تیز اور مستحکم۔
ویڈیو ایڈیٹنگ	DaVinci Resolve اور Adobe طرز کے ایڈیٹرز کے لیے بہترین۔	DaVinci Resolve اور Kdenlive اچھے چلتے ہیں۔ کچھ تجارتی ایڈیٹرز موجود نہیں۔
بیک گراؤنڈ سروسز اور Docker	ممکن (Docker Desktop، WSL2)، مگر بھاری۔	مقامی، ہلکا، اور ہمیشہ چلنے والے سرور کے لیے قابلِ اعتماد۔
وسائل کا استعمال	خالی حالت میں زیادہ RAM (اکثر 3 تا 4 GB)۔	خالی حالت میں کم RAM (اکثر 1 تا 2 GB)، جو ماڈلز کے لیے زیادہ بچتی ہے۔
اپ ڈیٹس	خودکار، کبھی کبھی نامناسب وقت پر۔	آپ کے کنٹرول میں؛ لاپروائی سے اپ ڈیٹ کرنے پر ڈرائیور ٹوٹ سکتا ہے۔

سیکھنے کی قدر	اچھی۔	بہت اچھی؛ AI انجینئرنگ کی مہارتیں کلاؤڈ سرورز پر سیدھی منتقل ہوتی ہیں۔

4.3 پرتیں کیسے جڑتی ہیں



Option A keeps Windows software; Option B gives the least overhead.

In WSL2 never install a separate Linux NVIDIA driver. The Windows driver is shared automatically.

شکل 4.1 دو درست ترتیبیں۔ ایک چنیں، پھر NVIDIA ڈرائیور کو درست پرت میں رکھیں۔ (ڈایاگرام کے لیبل انگریزی میں ہیں)

4.4 کون سا Linux ڈسٹری بیوشن؟

ڈسٹری بیوشن	کس کے لیے بہتر	نوٹس
Ubuntu Desktop 24.04 LTS	زیادہ تر لوگ؛ پہلا Linux سسٹم	پانچ سال کی معیاری سپورٹ۔ سب سے بڑی مدد کی کمیونٹی۔ پہلی تجویز۔
Ubuntu Server 24.04 LTS	بغیر اسکرین کی ہوم لیب مشین، جو دور سے کنٹرول ہو	کوئی ڈیسک ٹاپ نہیں۔ ہمیشہ چلنے والے Ollama اور Open WebUI کے لیے مثالی۔ انتظام کے لیے دوسرا کمپیوٹر یا SSH درکار۔
Linux Mint 22	کلاسک ڈیسک ٹاپ اور پرسکون، مستحکم بنیاد چاہنے والے	Ubuntu LTS پر مبنی۔ ڈرائیور سیٹ اپ گرافیکل ٹول سے۔
Pop!_OS 22.04 یا بعد کا	NVIDIA مالکان جو ڈرائیور پہلے سے تیار چاہیں	NVIDIA کے لیے تیار امیج۔ گیمنگ اور تخلیقی کام کے لیے اچھا۔
Debian 12 (stable)	تجربہ کار صارفین جو بہت مستحکم سرور چاہیں	نئے ڈرائیور دیر سے آتے ہیں؛ نئے NVIDIA کارڈز کے لیے backports درکار ہو سکتے ہیں۔
Fedora، Arch، openSUSE	شوقین صارفین	نئے پیکجز اور زیادہ دستی کام۔ پہلے AI سسٹم کے طور پر تجویز نہیں۔

سفارش

اگر فیصلہ نہ ہو سکے: ایک مشین کے لیے جسے آپ ایڈیٹنگ کے لیے بھی استعمال کریں تو Ubuntu Desktop 24.04 LTS، اور بغیر اسکرین کی مخصوص مشین کے لیے Ubuntu Server 24.04 LTS۔ جو سسٹم ویڈیو بناتے وقت مسلسل چلنا چاہیے، اس کے لیے rolling-release ڈسٹری بیوشن سے بچیں۔

4.5 ڈual boot یا ایک ہی سسٹم؟

Dual boot (ایک ڈسک پر Windows اور Linux، شروع میں انتخاب) ممکن ہے مگر اس میں خطرات ہیں: Windows کے اپ ڈیٹس boot menu بدل سکتے ہیں، اور ڈسک کی ترتیب احتیاط سے طے کرنی پڑتی ہے۔ زیادہ تر سیکھنے والوں کے لیے Windows کے ساتھ WSL2 یا ایک الگ Linux مشین سادہ ترین ہے۔ اگر dual boot کریں تو پہلے بیک اپ لیں، اور Linux کے لیے کم از کم 100 GB اور ماڈلز کے لیے 200 GB رکھیں۔

باب 5

سسٹم تیار کرنا، قدم بہ قدم

یہ باب ہارڈ ویئر اور آپریٹنگ سسٹم کو تیار کرتا ہے۔ قدم ترتیب سے کریں۔ اگر کوئی قدم ناکام ہو تو آگے بڑھنے سے پہلے خرابیوں کے حل کا نوٹ پڑھ لیں۔ کمانڈز Ubuntu کے لیے دی گئی ہیں، اور جہاں Windows کے ساتھ WSL2 پر فرق ہے وہاں الگ بتایا گیا ہے۔

5.1 قدم 1: بیک اپ لیں اور موجودہ حالت لکھیں

1. اپنی ذاتی فائلیں بیرونی ڈسک یا کلاؤڈ اسٹوریج میں بیک اپ کریں۔
2. مشین کا ماڈل، RAM، گرافکس کارڈ، ڈسک کا سائز اور خالی جگہ لکھ لیں۔ باب 14 میں یہ اعداد کام آئیں گے۔
3. طے کریں کہ ماڈلز کو کتنے گیگا بائٹ دے سکتے ہیں۔ تیز SSD پر کم از کم 200 GB خالی ہونا اچھا ہے۔

5.2 قدم 2: BIOS / UEFI کی ترتیبات

ری اسٹارٹ کریں اور BIOS میں جائیں (عموماً شروع ہوتے وقت Delete، F2 یا F10 دبا کر)۔ یہ تلاش کریں اور سیٹ کریں:

- **Above 4G Decoding:** فعال (Enabled)، کیونکہ 8 GB یا زیادہ والے کئی گرافکس کارڈز کو اس کی ضرورت ہے۔
- **Resizable BAR / Smart Access Memory:** اگر دستیاب ہو تو فعال کریں۔ کچھ ٹولز کی رفتار بہتر ہو سکتی ہے۔
- **Virtualization (Intel VT-x یا AMD-V / SVM):** فعال، Docker اور WSL2 کے لیے ضروری۔
- **Primary graphics:** اگر مانیٹر NVIDIA کارڈ سے جڑا ہو تو اسے dedicated (PCIe) گرافکس پر رکھیں، انٹیگریٹڈ پر نہیں۔
- **Power profile:** "Balanced" یا "Performance" رہنے دیں۔ ایسا کم بجلی والا موڈ نہ لگائیں جو CPU کو محدود کرے۔

5.3 قدم 3: مشین کو صاف اور ٹھنڈا رکھیں

- کیس کھولیں اور پنکھوں، ہیٹ سنکس اور گرافکس کارڈ سے گرد کمپریسڈ ہوا سے صاف کریں (یہ باہر کریں، اور پنکھوں کو ہاتھ سے ساکن رکھیں)۔
- یقینی بنائیں کہ کیس کے آگے یا نیچے کم از کم ایک ہوا اندر لانے والا اور پیچھے یا اوپر ایک ہوا باہر نکالنے والا پنکھا ہو۔
- لیپ ٹاپ کے لیے ہوا کے سوراخ صاف کریں اور اسے کسی سخت، اونچی سطح پر رکھیں۔ اگر پنکھے شور کریں تو کولنگ اسٹینڈ استعمال کریں۔

5.4 قدم 4: آپریٹنگ سسٹم انسٹال یا اپ ڈیٹ کریں

Windows 11 کا راستہ: Windows Update اس وقت تک چلائیں جب تک کوئی اپ ڈیٹ باقی نہ رہے، پھر NVIDIA کی ویب سائٹ سے تازہ ترین Game Ready یا Studio ڈرائیور انسٹال کریں، اور ری اسٹارٹ کریں۔

Ubuntu کا راستہ: Ubuntu Desktop 24.04 LTS (یا Server) ڈاؤن لوڈ کریں، اسے Rufus (Windows)، balenaEtcher یا Startup Disk Creator جیسے ٹول سے USB اسٹک پر لکھیں، USB سے boot کریں اور انسٹال کریں۔ "Erase disk" صرف تب چنیں جب ڈسک صرف Linux کے لیے ہو۔ انسٹالیشن کے بعد چلائیں:

```
sudo apt update && sudo apt full-upgrade -y
sudo reboot
```

5.5 قدم 5: NVIDIA ڈرائیور انسٹال کریں (Linux)

Ubuntu خود بہترین ڈرائیور تلاش کر کے انسٹال کر سکتا ہے:

```
ubuntu-drivers devices           # lists your GPU and the recommended driver
sudo ubuntu-drivers install      # installs the recommended driver
sudo reboot
```

ری اسٹارٹ کے بعد جانچیں کہ کارڈ فعال ہے:

```
nvidia-smi
```

آؤٹ پٹ میں آپ کے کارڈ کا نام (مثلاً "NVIDIA GeForce RTX 3060")، ڈرائیور کا ورژن، اور میموری کا کل حجم (مثلاً "12288MiB") نظر آنا چاہیے۔ اس باب کی یہ سب سے اہم جانچ ہے۔ اگر کمانڈ نہ ملے تو ڈرائیور انسٹال نہیں ہوا: `sudo ubuntu-drivers install` دوبارہ چلائیں اور ری اسٹارٹ کریں، یا باب 14 میں بتائی گئی Secure Boot کی ترتیبات آزمائیں۔

5.6 قدم 6: WSL2 سیٹ اپ کریں (Windows استعمال کرنے والے جنہیں Linux ٹولز چاہئیں)

PowerShell کو Administrator کے طور پر کھولیں اور چلائیں:

```
wsl --install -d Ubuntu-24.04
wsl --update
```

جب کہا جائے تو ری اسٹارٹ کریں، پھر Linux کا یوزر نام اور پاس ورڈ بنائیں، اور Start مینو سے Ubuntu کھولیں۔ Ubuntu کے اندر GPU چیک کریں:

```
nvidia-smi
```

اگر کارڈ نظر آئے تو WSL2 درست طور پر Windows کا ڈرائیور استعمال کر رہا ہے۔ WSL2 کے اندر Linux کا NVIDIA ڈرائیور الگ سے انسٹال نہ کریں۔

5.7 قدم 7: فولڈرز کی مناسب ترتیب بنائیں

صاف ترتیب خودکار کام (باب 13) کو آسان بناتی ہے۔ اپنے ہوم فولڈر میں یہ ڈھانچہ بنائیں۔ Windows پر یہی ناموں کو اپنے یوزر فولڈر یا WSL2 کے Ubuntu ہوم فولڈر کے اندر رکھیں۔

```
~/homelab/
  models/            large model files you download yourself
  studio/
    01_ideas/
    02_scripts/
    03_voice/
    04_images/
    05_clips/
    06_projects/     editor project files
    07_exports/      final videos
    08_thumbnails/
    09_logs/         notes about each run and each decision
  docker/            configuration for Open WebUI and other services
```

```
mkdir -p ~/homelab/models ~/homelab/docker
~/homelab/studio/{01_ideas,02_scripts,03_voice,04_images,05_clips,06_projects,07_exports,08
_thumbnails,09_logs}
```

5.8 قدم 8: swap اسپیس شامل کریں (RAM کے لیے حفاظتی جال)

Swap وہ ڈسک کی جگہ ہے جو RAM ختم ہونے پر استعمال ہوتی ہے۔ یہ RAM سے بہت سست ہے، اس لیے کریش سے بچاتا ہے مگر میموری کی جگہ نہیں لیتا۔ 16 GB RAM والے Ubuntu پر 16 GB کی swap فائل معقول حفاظتی جال ہے:

```
sudo fallocate -l 16G /swapfile
sudo chmod 600 /swapfile
sudo mkswap /swapfile
sudo swapon /swapfile
echo '/swapfile none swap sw 0 0' | sudo tee -a /etc/fstab
```

`free -h` سے جانچیں۔ Windows پر page file خود سنبھالی جاتی ہے؛ Advanced System Settings میں اسے "System managed" رکھیں۔

5.9 قدم 9: Docker انسٹال کریں (اختیاری مگر تجویز کردہ)

Docker Open WebUI جیسی سروسز کو الگ تھلگ containers میں چلاتا ہے، تاکہ انہیں اپ ڈیٹ اور ہٹانا آسان ہو۔

Ubuntu پر:

```
sudo apt install -y docker.io docker-compose-v2
sudo usermod -aG docker $USER
newgrp docker
docker run --rm hello-world
```

Windows پر Docker Desktop انسٹال کریں اور اس کی ترتیبات میں WSL2 backend فعال کریں۔

5.10 قدم 10: نگرانی کے ٹولز انسٹال کریں

جو چیز نظر نہ آئے اسے سنبھالا نہیں جا سکتا۔ ایسے ٹولز انسٹال کریں جو ماڈلز چلتے وقت VRAM، RAM اور درجہ حرارت دکھائیں:

```
sudo apt install -y htop btop nvtop        # Ubuntu: CPU, RAM, GPU monitors
watch -n 1 nvidia-smi                       # live GPU view in any terminal
```

Windows پر Task Manager کا Performance ٹیب GPU میموری اور درجہ حرارت دکھاتا ہے، اور PowerShell میں `nvidia-smi` بھی کام کرتا ہے۔

5.11 قدم 11: مشین کا ایک بار بینچ مارک لیں

ابھی ایک بنیادی ریکارڈ بنائیں تاکہ بعد میں موازنہ ہو سکے۔ خالی ڈسک (`df -h ~`)، خالی RAM (`free -h`) اور GPU کا نام (`nvidia-smi`) نوٹ کریں۔ اسے `~/homelab/studio/09_logs/baseline.txt` میں رکھیں۔

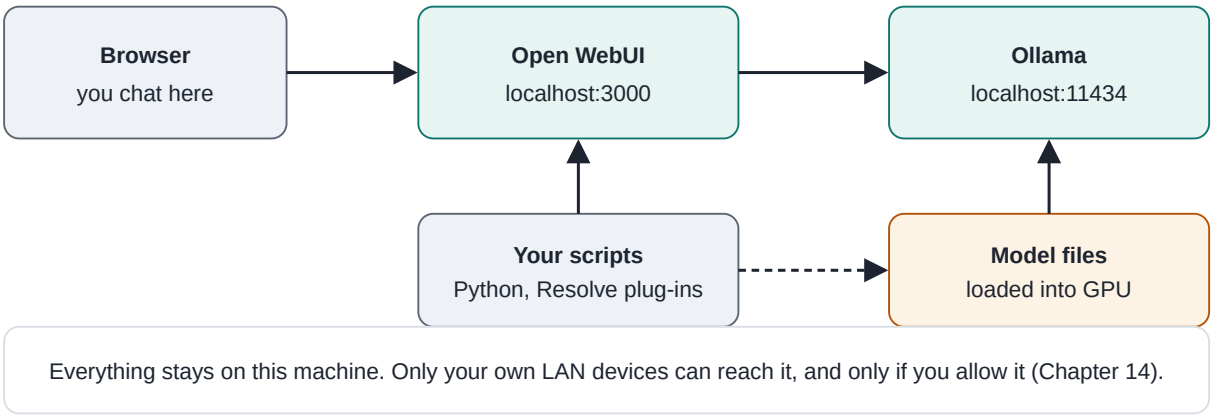
> **حفاظت**
>
> surge protector یا UPS استعمال کریں۔ ماڈل ڈاؤن لوڈ یا ویڈیو رینڈر کے دوران اچانک بجلی جانے سے فائلیں خراب ہو سکتی ہیں۔ مشین کو ہوادار جگہ پر رکھیں؛ لوڈ کے تحت GPU 70 تا 85 ڈگری سیلسیئس تک جا سکتا ہے بغیر throttling کے، مگر اس سے زیادہ گرمی کولنگ کا مسئلہ ہے۔

باب 6

بنیادی AI اسٹیک انسٹال کرنا اور پہلی گفتگو

6.1 چار بنیادی اجزاء

- **Ollama** (یا LM Studio): لینگوئج ماڈلز چلاتا ہے اور آپ کی مشین پر ایک سادہ پروگرامنگ انٹرفیس (API) دیتا ہے۔
- **Open WebUI:** براؤزر میں چیٹ کا انٹرفیس جو Ollama سے بات کرتا ہے۔ یہ چیٹ ویب سائٹ کی طرح دکھتا ہے، مگر آپ کے کمپیوٹر پر چلتا ہے۔
- **ComfyUI:** تصویر اور ویڈیو بنانے کے لیے نوڈ پر مبنی ٹول (ابواب 9 اور 11)۔
- **آپ کا ایڈیٹر اور اسکرپٹس:** DaVinci Resolve یا Kdenlive، اور آٹومیشن کے لیے Python (باب 13)۔



شکل 6.1 اجزاء آپس میں کیسے بات کرتے ہیں۔ اسکرپٹس براؤزر کو چھوڑ کر براہِ راست Ollama کو کال کر سکتے ہیں۔ (ڈایاگرام کے لیبل انگریزی میں ہیں)

6.2 Ollama انسٹال کریں

Linux (Ubuntu، Mint، Pop!_OS): ollama.com سے سرکاری انسٹالر چلائیں (سائٹ کھول کر موجودہ Linux کمانڈ کاپی کریں)، پھر جانچیں:

```
ollama --version
systemctl status ollama      # the background service should be "active (running)"
```

Windows: ollama.com سے Windows انسٹالر ڈاؤن لوڈ کر کے چلائیں۔ یہ پس منظر میں شروع ہوتا ہے اور NVIDIA ڈرائیور خودکار طور پر استعمال کرتا ہے۔

6.3 آپ کا پہلا ماڈل

پہلی جانچ کے لیے چھوٹا ماڈل لیں تاکہ جلدی ہو۔ 3 تا 4 ارب پیرامیٹر والا ماڈل 8 GB کے لیپ ٹاپ پر بھی چلتا ہے:

```
ollama pull llama3.2:3b          # downloads about 2 GB
ollama run llama3.2:3b           # opens a chat in the terminal
```

ایک سوال لکھیں، Enter دبائیں اور جواب پڑھیں۔ باہر آنے کے لیے `/bye` لکھیں۔ پھر دیکھیں ماڈل کہاں چلا:

```
ollama ps
```

PROCESSOR کالم اہم ہے۔ "100% GPU" کا مطلب ہے کہ ماڈل مکمل طور پر VRAM میں ہے، جو آپ چاہتے ہیں۔ "48%/52% CPU/GPU" جیسی تقسیم کا مطلب ہے کہ ماڈل کا کچھ حصہ سسٹم RAM میں ہے اور جواب سست ہوگا۔

6.4 Open WebUI کے ساتھ براؤزر چیٹ شامل کریں

Docker انسٹال ہونے کے بعد (قدم 9) یہ چلائیں:

```
docker run -d -p 3000:8080 \
  --add-host=host.docker.internal:host-gateway \
  -v open-webui:/app/backend/data \
  --name open-webui --restart always \
  ghcr.io/open-webui/open-webui:main
```

`http://localhost:3000` براؤزر میں کھولیں، مقامی ایڈمنسٹریٹر اکاؤنٹ بنائیں (جو صرف اس مشین پر محفوظ ہوتا ہے)، اور مینو سے ماڈل چنیں۔ پہلی بار شروع ہونے میں چند منٹ لگتے ہیں۔ Open WebUI `host.docker.internal:11434` کے ذریعے Ollama تک پہنچتا ہے، جو اوپر کی کمانڈ میں ترتیب دیا گیا ہے۔

> **سیکیورٹی**
> پورٹ 3000 یا 11434 کو انٹرنیٹ پر کھلا نہ چھوڑیں۔ Ollama ڈیفالٹ میں لاگ اِن نہیں مانگتا۔ گھریلو نیٹ ورک پر دونوں کو مقامی مشین تک محدود رکھیں جب تک کوئی خاص وجہ نہ ہو، اور فائر وال استعمال کریں (Ubuntu: `sudo ufw allow from 192.168.1.0/24 to any port 3000`، صرف اپنے سب نیٹ کے لیے)۔

6.5 اسکرپٹ سے API آزمائیں

اسکرپٹس HTTP کے ذریعے Ollama سے بات کرتے ہیں۔ یہ کمانڈ ایک مختصر جواب مانگتی ہے اور JSON واپس دیتی ہے:

```
curl http://localhost:11434/api/generate -d '{
  "model": "llama3.2:3b",
  "prompt": "Give three hook sentences for a video about budget home AI.",
  "stream": false
}'
```

Python میں سرکاری لائبریری `pip install ollama` سے انسٹال کریں، پھر:

```
import ollama

reply = ollama.chat(
    model="llama3.2:3b",
    messages=[{"role": "user", "content": "Write a 20-second intro for a tech channel."}],
)
print(reply["message"]["content"])
```

6.6 LM Studio انسٹال کریں (اختیاری متبادل)

LM Studio ایک ڈیسک ٹاپ ایپ ہے جس میں ماڈل تلاش کرنے کی جگہ، چیٹ ونڈو اور مقامی سرور ہے۔ ابتدائی صارفین کے لیے Windows اور Mac پر آسان ہے۔ lmstudio.ai سے انسٹال کریں، ماڈل تلاش کر کے ڈاؤن لوڈ اور لوڈ کریں۔ آپ اس کا مقامی سرور بھی شروع کر سکتے ہیں اور اسی طرح کا API استعمال کر سکتے ہیں۔ LM Studio کا سرور اور Ollama ایک ہی وقت میں ایک ہی پورٹ پر نہ چلائیں؛ اگر دونوں پورٹ 11434 یا 1234 استعمال کر رہے ہوں تو ایک کی ترتیب بدلیں۔

6.7 ComfyUI انسٹال کریں (آئندہ ابواب کے لیے)

ComfyUI ابھی انسٹال کریں تاکہ جب ضرورت ہو تو فولڈرز موجود ہوں۔ Windows صارفین ComfyUI کے releases صفحے سے portable پیکج ڈاؤن لوڈ کر سکتے ہیں۔ Linux صارف یہ چلائیں:

```
cd ~/homelab
git clone https://github.com/comfyanonymous/ComfyUI.git
cd ComfyUI
python3 -m venv .venv
source .venv/bin/activate
pip install torch torchvision --index-url https://download.pytorch.org/whl/cu124
pip install -r requirements.txt
python main.py
```

`cu124` والا حصہ آپ کے ڈرائیور کے سپورٹڈ CUDA ورژن سے میل کھانا چاہیے۔ PyTorch کی ویب سائٹ آپ کے سسٹم کے لیے درست کمانڈ بنا کر دیتی ہے؛ اگر اوپر والی ناکام ہو تو وہی استعمال کریں۔ ComfyUI `http://127.0.0.1:8188` پر کھلتا ہے۔ روکنے کے لیے Ctrl+C دبائیں۔

6.8 پہلے دن کی چیک لسٹ

جانچ	کمانڈ یا جگہ	متوقع نتیجہ
GPU نظر آ رہا ہے	`nvidia-smi`	آپ کے کارڈ کا نام اور کل میموری
Ollama چل رہا ہے	`ollama list`	وہ ماڈل دکھائے جو آپ نے ڈاؤن لوڈ کیا
ماڈل GPU پر ہے	چیٹ کے دوران `ollama ps`	3B یا 7B ماڈل کے لیے "GPU %100"
براؤزر چیٹ کام کر رہی ہے	`http://localhost:3000`	چیٹ ونڈو جواب دے
اسکرپٹ کام کر رہا ہے	6.5 کا Python ٹکڑا	ایک مختصر جواب چھاپے
ڈسک کی جگہ	`df -h ~`	انسٹالیشن کے بعد کم از کم 150 GB خالی

> **سنگ میل**
>
> جب یہ چھ جانچیں کامیاب ہو جائیں تو بنیادی ہوم لیب کام کر رہی ہے۔ اس کورس کی باقی ہر چیز اسی بنیاد پر کھڑی ہے۔

LLM ماڈلز کا انتخاب

7.1 ماڈل کیا ہے

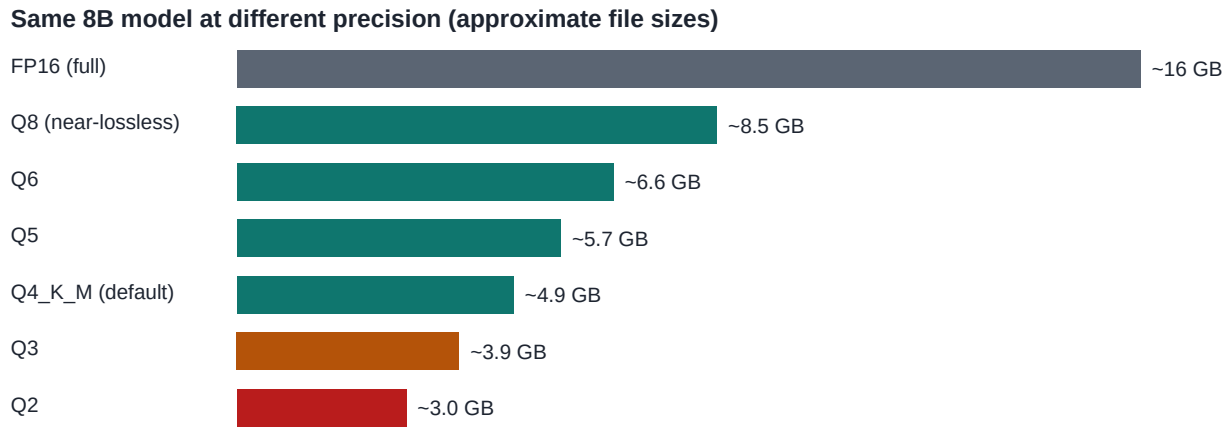
لینگوئج ماڈل نمبروں کی ایک فائل ہے، جسے *weights* (وزن) کہتے ہیں، جس نے بہت بڑے متن سے پیٹرن سیکھے ہیں۔ جب آپ اسے پرامپٹ بھیجتے ہیں تو وہ اگلا لفظ (token) پیش گوئی کرتا ہے، بار بار، جب تک جواب مکمل نہ ہو۔ ماڈل چار طریقوں سے مختلف ہوتے ہیں جو آپ کے لیے اہم ہیں: سائز، کمپریشن، مہارت اور لائسنس۔

7.2 سائز: پیرامیٹرز کی تعداد

پیرامیٹرز وہی وزن ہیں۔ "7B" کا مطلب ہے تقریباً سات ارب پیرامیٹرز۔ عموماً بڑا ماڈل پیچیدہ ہدایات بہتر سمجھتا ہے، کم حقائق میں غلطی کرتا ہے اور قدرتی انداز میں لکھتا ہے، مگر اسے زیادہ میموری چاہیے اور وہ آہستہ چلتا ہے۔ یوٹیوب پروڈکشن کے لیے 7B اور 14B کے فرق سے اسکرپٹ اور منصوبہ بندی میں واضح فرق آتا ہے، جبکہ سادہ عنوانات یا ٹیگز میں فرق کم ہوتا ہے۔

7.3 کمپریشن: quantization

ماڈلز عموماً فی وزن 16 بٹس میں محفوظ ہوتے ہیں۔ Quantization ہر وزن کو کم بٹس میں محفوظ کرتی ہے، جس سے فائل اور اس کی درکار میموری سکڑ جاتی ہے، اور معیار میں تھوڑی کمی آتی ہے۔ Ollama اور LM Studio عموماً quantized ورژن ڈیفالٹ میں ڈاؤن لوڈ کرتے ہیں، جن کے نام `Q4_K_M` جیسے ہوتے ہیں۔ 7B سے 14B ماڈل کے لیے Q4_K_M عموماً بہترین توازن ہے۔ Q5 اور Q6 تھوڑے بہتر مگر بڑے ہوتے ہیں۔ Q2 اور Q3 اکثر نمایاں طور پر کمزور ہوتے ہیں۔



شکل 7.1 Quantization، فائل کے سائز کے بدلے معیار کا توازن بدلتی ہے۔ سائز ایک 8B ماڈل کے لیے تقریباً ہیں۔ (ڈایاگرام کے لیبل انگریزی میں ہیں)

7.4 مہارت

- **عمومی چیٹ ماڈلز** (جن کے نام میں "instruct" یا "chat" ہو): لکھنے، منصوبہ بندی اور سوال و جواب کے لیے ڈیفالٹ۔
- **Reasoning ماڈلز:** جواب سے پہلے اضافی tokens میں "سوچتے" ہیں۔ مشکل منطق یا منصوبہ بندی کے لیے بہتر، عملی طور پر سست (باب 8)۔
- **کوڈنگ ماڈلز:** سورس کوڈ پر تربیت یافتہ۔ پروگرام لکھنے اور ٹھیک کرنے میں بہتر (باب 8)۔
- **Vision ماڈلز:** تصویر ان پٹ کے طور پر قبول کرتے ہیں؛ تھمب نیل جانچنے یا فریم بیان کرنے کے لیے مفید۔
- **Embedding ماڈلز:** متن کو تلاش کے لیے نمبروں میں بدلتے ہیں۔ زیادہ تر ابتدائی صارفین کو ابھی ضرورت نہیں، مگر آگے چل کر اپنے اسکرپٹس کی تلاش کے قابل لائبریری بنانے میں مفید ہیں۔

7.5 لائسنس: کیا آپ اسے منافع بخش چینل کے لیے استعمال کر سکتے ہیں؟

ماڈلز کے لائسنس مختلف ہوتے ہیں۔ کچھ سادہ شرائط کے ساتھ تجارتی استعمال کی اجازت دیتے ہیں (مثلاً Apache 2.0 یا MIT)۔ دوسرے "صرف تحقیق" یا "غیر تجارتی" ہوتے ہیں، اور کچھ حوالہ (attribution) دکھانے کو کہتے ہیں۔ آپ کا چینل پیسے کما سکتا ہے، اس لیے ہر اس ماڈل کا لائسنس چیک کریں جو حتمی آؤٹ پٹ کے لیے استعمال ہو۔ ضمیمہ C میں مختصر رہنمائی ہے۔ شک ہو تو جو کچھ شائع کریں اس کے لیے Apache 2.0 یا MIT والے ماڈل استعمال کریں، اور باقی کو صرف سیکھنے کے ٹولز سمجھیں۔

7.6 لکھنے کے وقت کے مثالی ماڈل خاندان

ماڈلز کے نام اور tags اکثر بدلتے ہیں۔ نیچے دیے گئے ناموں کو ابتدائی نقطہ سمجھیں اور ڈاؤن لوڈ سے پہلے Ollama لائبریری کے صفحے پر موجودہ tag کی تصدیق کریں۔

آپ کی میموری (VRAM یا unified)	چیٹ اور تحریر	Reasoning	کوڈنگ
صرف CPU، 8 GB RAM	llama3.2:3b، gemma3:1b	deepseek-r1:1.5b (بنیادی)	qwen2.5-coder:1.5b
6 تا 8 GB VRAM	qwen2.5:7b، llama3.1:8b، gemma3:4b	deepseek-r1:7b یا 8b	qwen2.5-coder:7b
12 GB VRAM	gemma3:12b، qwen2.5:14b (تقریباً 9 GB، context کے لیے جگہ چھوڑتا ہے؛ `ollama ps` میں "100% GPU" کی تصدیق کریں)	deepseek-r1:14b	qwen2.5-coder:14b
16 GB VRAM	qwen2.5:14b، phi4:14b	deepseek-r1:14b (تیز)؛ اگر سما جائے تو gpt-oss:20b	qwen2.5-coder:14b
24 GB VRAM یا 32 GB unified Mac	qwen2.5:32b، gemma3:27b	deepseek-r1:32b، gpt-oss:20b آرام سے	qwen2.5-coder:32b

عوامی اشاعت سے پہلے ہر ماڈل کا لائسنس اس کے صفحے پر دیکھیں۔ ماڈل ڈاؤن لوڈ کرنے کے لیے `ollama pull <name>` چلائیں۔ غیر استعمال شدہ ماڈل ہٹانے کے لیے `ollama rm <name>` چلائیں تاکہ ڈسک کی جگہ بچے۔

7.7 انتخاب کیسے کریں: ایک عملی طریقہ

1. **اپنی ہارڈ ویئر کی حد طے کریں۔** اوپر کی جدول اور باب 2 کا میموری اصول استعمال کریں۔ 1 تا 2 GB خالی رکھیں۔
2. **توقع سے ایک سائز چھوٹے سے شروع کریں** اور `ollama ps` اور جواب کا وقت ناپ کر رفتار جانچیں۔
3. **اپنا ذاتی ٹیسٹ سیٹ بنائیں۔** اپنے چینل کے پانچ حقیقی کام لکھیں: 60 سیکنڈ کا ہُک، حقائق کی فہرست، عنوانات کا سیٹ، ایک پروڈکٹ کا موازنہ، اور ایک مشکل منطقی سوال۔ انہیں `~/homelab/studio/09_logs/tests.txt` میں محفوظ کریں۔
4. **ہر امیدوار کو وہی ٹیسٹ دیں** اور جوابات کو خود 1 تا 5 کے پیمانے پر درستگی، انداز اور ہدایات پر عمل کے لیے نمبر دیں۔
5. **وہ سب سے چھوٹا ماڈل چنیں جو آپ کے کاموں میں اچھا اسکور کرے۔** ایک تیز اور کافی حد تک اچھا ماڈل اس بڑے ماڈل سے زیادہ قیمتی ہے جس کا آپ انتظار کرتے رہیں۔

> **مشورہ**
>
> عام بینچ مارک کی عوامی فہرستیں شارٹ لسٹ کے لیے مفید ہیں، مگر فیصلہ آپ کا اپنا ٹیسٹ سیٹ کرے۔ جو ماڈل عام بینچ مارک میں سب سے آگے ہو، وہ یوٹیوب کے اچھے ہُک نہ لکھ سکے۔

Context کی لمبائی 7.8

Context وہ متن ہے جو ماڈل ایک وقت میں مدنظر رکھ سکتا ہے: آپ کا پرامپٹ، گفتگو اور جواب۔ 2,048 تا 4,096 tokens کا ڈیفالٹ لمبی اسکرپٹ کے لیے کم ہے۔ چیٹ میں اسے یوں بڑھائیں:

```
ollama run qwen2.5:7b
>>> /set parameter num_ctx 8192
```

context دوگنا کرنے پر زیادہ VRAM لگتی ہے۔ اگر ماڈل CPU اور GPU میں تقسیم ہونے لگے تو context دوبارہ کم کریں۔ 1,500 الفاظ کی ایک اسکرپٹ تقریباً 2,000 tokens ہوتی ہے، تو 8,192 میں اسکرپٹ، نوٹس اور فیڈ بیک کی گنجائش ہے۔

باب 8

گہری سوچ، کوڈنگ اور اسکرپٹس کے لیے LLMs

8.1 "سوچنے" کے کام کی تین قسمیں

کام کی قسم	بہترین ماڈل کی قسم	عام آؤٹ پٹ کی رفتار	کس کام کے لیے
فوری تحریر	عمومی چیٹ ماڈل 7B تا 14B	تیز (اچھے کارڈ پر 20 تا 60 tokens/s)	ہُکس، خاکے، عنوانات، تفصیلات، دوبارہ لکھائی
گہری سوچ	Reasoning ماڈل (مثلاً deepseek-r1 یا gpt-oss)	سست، کیونکہ ماڈل پہلے ایک لمبی اندرونی استدلال لکھتا ہے	منطق کی جانچ، کئی حصوں پر مشتمل سیریز کی منصوبہ بندی، دلیل میں خلا ڈھونڈنا، اسکرپٹ کی یکسانیت دیکھنا
کوڈنگ	کوڈنگ ماڈل (qwen2.5-coder)	تیز	وہ اسکرپٹس جو آپ کی پروڈکشن لائن کو جوڑیں، غلطیاں ٹھیک کرنا، کوڈ کی وضاحت

8.2 گہری سوچ: reasoning ماڈلز کو بہتر کیسے استعمال کریں

Reasoning ماڈلز اپنی سوچ ایک الگ حصے میں دکھاتے ہیں۔ اس سے وہ کئی مراحل والے مسائل میں بہتر ہوتے ہیں، مگر کافی سست بھی۔ انہیں ہر جملے کے لیے نہیں، چند اہم فیصلوں کے لیے استعمال کریں۔

- **اچھے استعمالات:** "یہ میری اسکرپٹ کی خاکہ ہے۔ تین منطقی خلا بتائیں جو ایک شکی ناظر دیکھے گا۔" یا: "6 ویڈیوز کی ایسی سیریز کی منصوبہ بندی کریں جو بنیادی سے جدید تک جائے، اور ویڈیوز کے درمیان انحصار واضح ہو۔"
- **کمزور استعمالات:** 50 عنوانات کی بڑی تعداد میں تیاری، جہاں تیز ماڈل وقت بچاتا ہے۔
- **مشورہ:** مختصر حتمی جواب مانگیں۔ ورنہ استدلال ہزاروں tokens تک چل سکتا ہے۔

8.3 دوبارہ استعمال ہونے والا اسکرپٹ رائٹر ماڈل

ہر بار لمبی ہدایت دہرانے کے بجائے ایک نامزد ماڈل بنائیں جس کا system message مقرر ہو۔ `~/homelab/studio` میں `Modelfile` نامی فائل بنائیں (بغیر extension کے):

```
FROM qwen2.5:7b
PARAMETER temperature 0.7
PARAMETER num_ctx 8192
SYSTEM """
You write scripts for an educational YouTube channel about practical technology.
Rules:
- Plain English, short sentences, one idea per sentence.
- Open with a hook of two sentences, then state what the viewer will learn.
- Mark each section with a heading in square brackets, for example [Section 2: Setup].
- Never invent statistics, prices or quotes. Write "[CHECK: ...]" where a fact must be
verified.
- Keep the spoken script between 130 and 150 words per minute of video.
"""
```

```
ollama create scriptwriter -f Modelfile
ollama run scriptwriter "Topic: why a used RTX 3060 is a good starting GPU for local AI.
Length: 8 minutes."
```

"[CHECK: ...]" والا اصول بہت اہم ہے۔ مقامی ماڈل پختہ یقین کے ساتھ غلط بھی ہو سکتے ہیں، اس لیے اسکرپٹ خود وہ دعوے نشان زد کرتی ہے جنہیں ریکارڈ سے پہلے آپ کو جانچنا ہے۔

8.4 یوٹیوب کے لیے کام کرنے والے پرامپٹس

کام	پرامپٹ کا ڈھانچہ
خاکہ	"موضوع: X۔ سامعین: بنیادی لیپ ٹاپ والے مبتدی۔ 6 حصے دیں، ہر ایک کا ایک سبق اور ایک مثال ہو۔"
ہُک کے اختیارات	"X کے بارے میں ویڈیو کے لیے 5 ابتدائی ہُکس لکھیں۔ ہر ایک 25 الفاظ سے کم ہو۔ انداز بدلیں: سوال، جرات مندانہ دعویٰ، کہانی، حیرت، چیلنج۔"
عنوان اور تھمب نیل کا متن	"60 حروف سے کم کے 10 عنوانات اور 3 الفاظ یا کم کے 10 تھمب نیل فقرے دیں۔ ایسے کلک بیٹ دعوے نہ کریں جو ویڈیو پورے نہ کرے۔"
تفصیل اور چیپٹرز	"150 الفاظ کی تفصیل لکھیں، اور یہ ٹائم اسٹیمپس استعمال کرتے ہوئے چیپٹر فہرست دیں: [یہاں چسپاں کریں]۔ ٹائم اسٹیمپس بالکل وہی رکھیں۔"
اسکرپٹ کا جائزہ	"یہ اسکرپٹ ایک شکی مبتدی کی نظر سے پڑھیں۔ الجھانے والے الفاظ، بغیر ثبوت کے دعوے، اور جہاں میں کوئی قدم چھوڑ دیتا ہوں، ان کی فہرست بنائیں۔"
لمبی ویڈیو سے شارٹس	"اس ٹرانسکرپٹ سے 3 لمحات چنیں جو 30 تا 45 سیکنڈ کے ہوں اور اپنے طور پر کھڑے ہوں۔ ہر ایک کا آغاز اور اختتام کا وقت اور ایک سطر کی وجہ دیں۔"

8.5 کوڈنگ کے مددگار

کوڈنگ ماڈل وہ چھوٹے پروگرام لکھ سکتا ہے جو آپ کے اسٹوڈیو کو جوڑیں: فائلوں کے نام بدلنا، اسکرپٹس کا بیچ بنانا، آڈیو لیول چیک کرنا، یا ComfyUI کو کال کرنا۔ اسے استعمال کرنے کے تین آسان طریقے:

- **Open WebUI:** کوڈ چسپاں کریں اور اصلاح یا وضاحت مانگیں۔ مبتدیوں کے لیے اچھا۔
- **Continue (VS Code ایکسٹینشن):** اسے اپنے Ollama سرور سے جوڑیں تاکہ ایڈیٹر میں براہِ راست تجاویز ملیں اور فائل پر گفتگو ہو سکے۔
- **Aider (کمانڈ لائن):** پورے پروجیکٹ فولڈر پر کام کرتا ہے۔ اسے `ollama/` پری فکس کے ساتھ مقامی Ollama ماڈل کی طرف اشارہ کریں۔ تبدیلیاں Git میں محفوظ رکھیں۔

اپنی فائلوں پر چلانے سے پہلے تیار کردہ کوڈ ضرور پڑھیں اور جانچیں۔ اپنے فولڈر کی کاپی پر شروع کریں۔ کوئی خودکار ٹول بیک اپ کے بغیر فائلیں نہ مٹائے۔

8.6 مقامی ماڈل استعمال کرنے والا چھوٹا بیچ اسکرپٹ

یہ مثال ایک متنی فائل سے ہر سطر میں ایک خیال پڑھتی ہے اور ہر ایک کا ابتدائی خاکہ scripts فولڈر میں لکھتی ہے۔ یہ صرف باب 6 میں انسٹال Ollama لائبریری استعمال کرتی ہے۔

```
import pathlib
import ollama

ideas = pathlib.Path("~/homelab/studio/01_ideas/ideas.txt").expanduser()
out_dir = pathlib.Path("~/homelab/studio/02_scripts/outlines").expanduser()
out_dir.mkdir(parents=True, exist_ok=True)

for n, line in enumerate(ideas.read_text(encoding="utf-8").splitlines(), start=1):
    if not line.strip():
        continue
    reply = ollama.chat(
        model="qwen2.5:7b",
        messages=[{"role": "user", "content": f"Write a 6-section outline for a video on:
{line}. "
                   "Mark anything that needs fact checking with [CHECK]."}],
    )
    (out_dir / f"outline_{n:03d}.md").write_text(reply["message"]["content"],
encoding="utf-8")
    print("done", n)
```

> **انسانی قدم**
>
> ہر خاکہ اور ہر اسکرپٹ آپ کو خود پڑھنا ہے۔ ماڈل مسودہ لکھتا ہے؛ کیا سچ، منصفانہ اور آپ کے سامعین کے لیے موزوں ہے، یہ فیصلہ آپ کا ہے۔

تصویر سازی (Image Generation)

9.1 تصویر سازی کیا اچھا کر سکتی ہے اور کیا نہیں

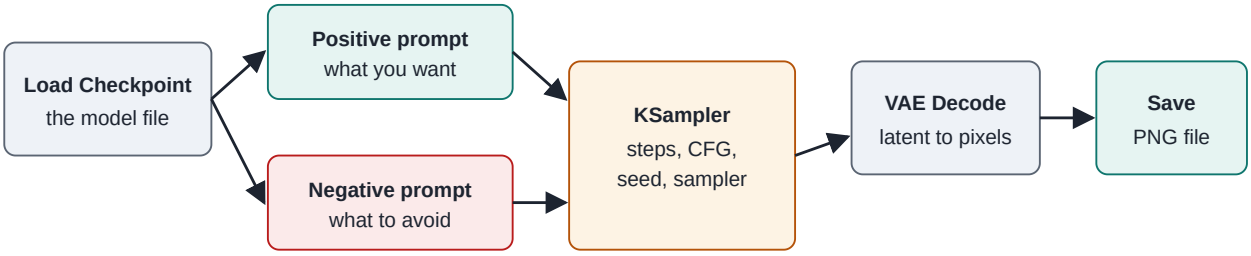
تصویری ماڈلز پس منظر، مناظر، پروڈکٹ کے ماک اپ، illustrations اور تجریدی کورز بنانے میں بہت اچھے ہیں۔ وہ دقیق متن، درست ہاتھوں اور بہت سی تصاویر میں مستقل کرداروں میں کمزور ہیں۔ تھمب نیل کے لیے پس منظر اور مرکزی شے AI سے بنائیں، پھر متن، تیر اور لوگو اپنے ایڈیٹر میں لگائیں، جہاں فونٹ اور ہجے آپ کے قابو میں ہوں۔

9.2 ماڈل خاندان

خاندان	اصل ریزولیوشن	VRAM کی ضرورت (تقریباً)	لائسنس (موجودہ شرائط چیک کریں)	نوٹس
Stable Diffusion 1.5	512 px	4 GB+	CreativeML OpenRAIL-M	سب سے پرانا، سب سے تیز، انداز کے add-ons کی بڑی لائبریری۔ کم تفصیل۔
SDXL اور اس کے ویرینٹس	1024 px	8 GB+	OpenRAIL++ (ہر ویرینٹ چیک کریں)	معمولی ہارڈ ویئر پر اچھا عمومی معیار۔
FLUX.1 schnell	1024 px	12 GB+ (quantized ورژن کم)	Apache 2.0	بہت اچھی تفصیل اور پرامپٹ پر عمل؛ کم steps کافی۔
FLUX.1 dev	1024 px	12 GB+ (quantized ورژن کم)	غیر تجارتی لائسنس	تجارتی لائسنس خریدے بغیر صرف سیکھنے اور جانچ کے لیے۔
نئے مؤثر ماڈلز (مثلاً Z-Image-Turbo)	1024 px	8 تا 16 GB	صفحے پر شرائط دیکھیں	اچھے معیار کے ساتھ تیز تخلیق؛ استعمال سے پہلے لائسنس چیک کریں۔

9.3 پائپ لائن کیسے بنتی ہے: ComfyUI

ComfyUI تخلیق کو nodes کہلانے والے ڈبوں کے گراف کے طور پر دکھاتا ہے۔ آپ کو پروگرامنگ کی ضرورت نہیں۔ آپ ڈبوں کو جوڑتے ہیں، محفوظ گراف (جسے workflow کہتے ہیں) لوڈ کرتے ہیں، اور Queue دباتے ہیں۔



Empty latent image (set width and height, for example 1024 x 1024) feeds the KSampler too.

Every node is a visible step. Click any node to change it; save the whole graph as a workflow file.

شکل 9.1 ایک بنیادی ComfyUI متن سے تصویر گراف۔ تیر دکھاتے ہیں کہ ڈیٹا ماڈل سے محفوظ شدہ تصویر تک کیسے بہتا ہے۔ (ڈایاگرام کے لیبل انگریزی میں ہیں)

9.4 انسٹالیشن اور پہلی تصویر

باب 6.7 میں بتایا گیا طریقہ استعمال کر کے ComfyUI انسٹال کریں۔ سرکاری صفحے سے ایک checkpoint (ماڈل فائل) ڈاؤن لوڈ کر کے `ComfyUI/models/checkpoints/` میں رکھیں۔ 8 GB کارڈ پر SDXL checkpoint سے شروع کریں، 12 GB پر FLUX schnell کا کوئی ورژن۔ ComfyUI دوبارہ شروع کریں۔ ڈیفالٹ workflow لوڈ کریں، اپنا checkpoint چنیں، پرامپٹ لکھیں اور Queue دبائیں۔

9.5 اہم ترتیبات

ترتیب	ابتدائی قدر	اثر
چوڑائی اور اونچائی	1024 x 1024 (SDXL، FLUX)؛ 512 x 512 (SD 1.5)	ماڈل کا اصل سائز استعمال کریں۔ بڑے سائز کو کہیں زیادہ VRAM چاہیے۔
Steps	20 تا 30 (SDXL)؛ 4 تا 8 (schnell یا Turbo ماڈلز، ماڈل کارڈ دیکھیں)	زیادہ steps سست ہیں، کبھی بہتر، ایک حد تک۔
CFG (رہنمائی)	SDXL کے لیے 5 تا 7؛ FLUX کے لیے ماڈل کارڈ کی پیروی کریں	زیادہ مطلب پرامپٹ پر سختی سے عمل، مگر تصویر سخت دکھ سکتی ہے۔
Seed	مقررہ عدد، مثلاً 42	وہی seed اور وہی ترتیبیں وہی تصویر دہراتی ہیں۔ نئی تلاش کے لیے بدلیں۔
Sampler	DPM++ 2M یا Euler (ڈیفالٹ ٹھیک ہے)	انداز اور رفتار میں تھوڑی تبدیلی۔

9.6 کارآمد پرامپٹس لکھنا

ایک قابلِ اعتماد پرامپٹ کے پانچ حصے تقریباً اسی ترتیب میں ہوتے ہیں:

```
[subject] + [action or setting] + [style] + [lighting] + [camera or composition] + [quality words]

Example:
"A young woman explaining a laptop screen in a bright home office, flat illustration style, soft window light, medium shot, clean shapes, high detail"
```

- **ٹھوس بنیں:** "ایک لکڑی کی میز پر چھوٹا GPU پنکھا" کہنا "ٹیکنالوجی" کہنے سے بہتر ہے۔
- **لوگ ہوں تو سامعین کا نام لیں۔** ورنہ ماڈل اپنا ڈیفالٹ انداز چن لیتا ہے، جو آپ کے ناظرین کے لیے موزوں نہ ہو۔
- **Negative prompts استعمال کریں** (SD اور SDXL میں) جیسے "blurry، extra fingers، watermark، text، signature"۔ FLUX ماڈلز مثبت الفاظ جیسے "plain background" پر بہتر ردعمل دیتے ہیں۔
- **پرامپٹ کا ریکارڈ رکھیں** `09_logs/` میں، جس میں seed، ماڈل اور ترتیبیں ہوں، تاکہ اچھی تصاویر دہرائی جا سکیں۔

9.7 تھمب نیل

یوٹیوب تھمب نیل 16:9 میں دکھائے جاتے ہیں۔ حتمی سائز 1280 x 720 پکسل رکھیں، فائل 2 MB سے کم رکھیں، اور مرکزی شے فون پر بھی بڑی اور پڑھنے کے قابل ہو۔ ایک عملی طریقہ:

1. 1344 x 768 پر 16:9 پس منظر بنائیں (یا 1024 x 576 تصویر بنا کر بڑھا لیں)۔
2. اہم حصے نیچے دائیں کونے سے دور رکھیں، جہاں ویڈیو کی لمبائی ظاہر ہوتی ہے۔
3. عنوان کے الفاظ، تیر اور لوگو اپنے ایڈیٹر یا کسی تصویری ایڈیٹر (GIMP، Krita، یا براؤزر میں Photopea) میں لگائیں۔
4. 1280 x 720 پر JPEG یا PNG برآمد کریں، اور فون کے سائز پر جانچیں۔

9.8 رفتار اور میموری کی تدبیریں

- 6 تا 8 GB کارڈز پر ComfyUI کو `python main.py --lowvram` سے شروع کریں۔ نتائج سست ہوں گے۔
- اگر مکمل ماڈل نہ سمائے تو بڑے ماڈلز کے چھوٹے یا quantized (GGUF یا fp8) ورژن استعمال کریں۔
- queue کے ذریعے رات کو بیچ میں تصاویر بنائیں۔ استعمال نہ ہونے والے ماڈلز checkpoint فولڈر سے ہٹا دیں تاکہ مینو صاف رہے۔
- preview سے خراب تصاویر جلد پہچانیں اور Cancel دبائیں، انتظار نہ کریں۔

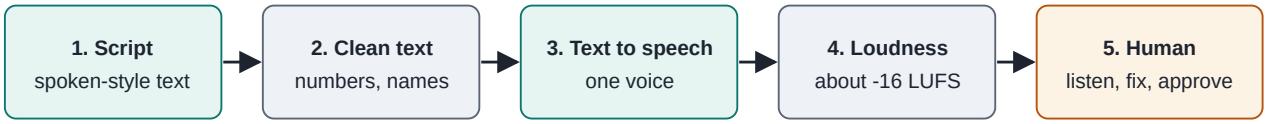
> **حقوق اور مشابہت**
>
> حقیقی لوگوں، معروف شخصیات یا نجی افراد کی تصاویر واضح رضامندی کے بغیر نہ بنائیں، اور کسی ایسے طریقے سے بھی نہیں جو ناظرین کو گمراہ کرے۔ جہاں یوٹیوب کے قواعد یا آپ کے ملک کا قانون تقاضا کرے، AI سے بنی تصاویر کا اعلان کریں۔ اپنے تخلیق کے ریکارڈ بطور ثبوت محفوظ رکھیں کہ ہر تصویر کیسے بنی۔

باب 10

بیانیہ اور آواز

10.1 آواز کی زنجیر

صاف وائس اوور کئی چھوٹے مراحل کا نتیجہ ہوتا ہے۔ ان میں سے کوئی ایک بھی چھوڑ دیں تو آواز "روبوٹک" یا ضرورت سے زیادہ بلند ہو سکتی ہے، جو سب سے عام مسئلہ ہے۔



Keep the final WAV (48 kHz, 16-bit) in 03_voice. Export only the approved file to the editor.

شکل 10.1 بیانیہ کی زنجیر۔ مرحلہ 5 کبھی نہیں چھوڑا جاتا۔ (ڈایاگرام کے لیبل انگریزی میں ہیں)

10.2 Text-to-speech کے اختیارات

ٹول	کہاں چلتا ہے	خوبی	کس بات کا خیال رکھیں
Piper	CPU، بہت ہلکا	تیز، بہت سی آوازیں، کہیں بھی چلتا ہے	آوازیں نئے ترین ماڈلز سے کچھ سادہ لگتی ہیں۔ ہر آواز کا لائسنس چیک کریں۔
Kokoro (82M)	CPU یا GPU، ہلکا	اپنے سائز کے لحاظ سے قدرتی آواز؛ وزن Apache 2.0 کے تحت	آوازوں کے انتخاب کم ہیں؛ تجارتی استعمال سے پہلے ماڈل کارڈ دیکھیں۔
F5-TTS	GPU تجویز کیا جاتا ہے	چھوٹی ریفرنس ریکارڈنگ سے آواز کی نقل (cloning)	صرف اپنی آواز یا وہ آواز جس کے لیے تحریری رضامندی ہو۔ لائسنس چیک کریں۔
XTTS-v2 (Coqui)	GPU تجویز کیا جاتا ہے	cloning اور کئی زبانیں	لائسنس تجارتی استعمال پر پابندی لگاتا ہے؛ تصدیق نہ ہو تو صرف سیکھنے کے لیے سمجھیں۔

پہلے چینل کے لیے **Kokoro** یا **Piper** سے شروع کریں: دونوں معمولی ہارڈ ویئر پر چلتے ہیں اور صاف، واضح بیانیہ دیتے ہیں۔ ایک مختصر ٹیسٹ اسکرپٹ رکھیں اور دو تین آوازوں کا کان سے موازنہ کریں۔ زیادہ تر تخلیق کار ایک آواز چنتے ہیں اور پورے چینل میں اسی کو رکھتے ہیں، کیونکہ ناظرین اسے پہچاننے لگتے ہیں۔

10.3 Piper کی ایک مختصر مثال

Piper voice ماڈل (ایک .onnx فائل اور اس کی .json config) Piper voices کے مجموعے سے ڈاؤن لوڈ کریں، پھر:

```
echo "Welcome. Today you will learn how to run a language model on your own computer." \
  | piper --model en_US-lessac-medium.onnx --output_file hook.wav
```

لمبی اسکرپٹ کو تقریباً 150 تا 300 الفاظ کے پیراگرافس میں تقسیم کریں، ہر پیراگراف کی ایک WAV بنائیں، اور ایڈیٹر میں جوڑیں۔ ایک ہی لمبی تخلیق میں اگر ایک جملہ غلط ہو جائے تو اسے ٹھیک کرنا مشکل ہے۔

10.4 کان کے لیے لکھیں

- **چھوٹے جملے۔** بولے جانے والا جملہ 12 تا 18 الفاظ کا ہو تو آسانی سے سمجھ آتا ہے۔
- **مشکل چیزیں پوری طرح لکھیں** جیسے ان کا تلفظ ہونا چاہیے: "R-T-X three zero six zero" یا "twelve gigabytes"، نہ کہ "RTX 3060 12GB"، جب تک انجن درست نہ پڑھے۔
- **وقفے کے لیے کاما اور فل اسٹاپ** استعمال کریں۔ ellipsis کم استعمال کریں۔
- **برانڈ کے ناموں اور تکنیکی اصطلاحات کی تلفظ کی فہرست** `03_voice/glossary.txt` میں رکھیں، اور ہر بار اسے چیک کریں۔

10.5 آواز کا لیول: ہر ویڈیو ایک جیسی آواز میں

یوٹیوب پلے بیک کو تقریباً -14 LUFS پر ایڈجسٹ کرتا ہے۔ تقریباً -16 LUFS (integrated) پر بیانیہ، جس کا true peak -1 dBTP یا اس سے کم ہو، فون اور لیپ ٹاپ پر بھرپور لگتا ہے اور بگاڑ نہیں ہوتا۔ اس کے لیے مفت ٹول FFmpeg استعمال کریں:

```
ffmpeg -i hook.wav -af loudnorm=I=-16:TP=-1.5:LRA=11 -ar 48000 hook_norm.wav
```

زیادہ کنٹرول والے نتیجے کے لیے DaVinci Resolve میں (Fairlight page) loudness meter یا Audacity میں LUFS plug-in استعمال کریں۔

10.6 سب ٹائٹلز کے لیے Speech-to-text

Speech recognition اس کا الٹ ہے: آڈیو سے متن۔ یہ سب ٹائٹلز اور ٹرانسکرپٹس، اور شارٹس کی کلپنگ کے لیے استعمال ہوتی ہے۔ تجویز کردہ کھلا ٹول **Whisper** ہے، خاص طور پر faster-whisper یا whisper.cpp ورژن:

```
pip install faster-whisper

from faster_whisper import WhisperModel

model = WhisperModel("small", device="cuda", compute_type="float16")   # use "cpu" and
"int8" without a GPU
segments, info = model.transcribe("03_voice/final_narration.wav", language="en")
for s in segments:
    print(f"{s.start:7.2f} {s.end:7.2f} {s.text}")
```

تکنیکی اصطلاحات پر بہتر درستگی کے لیے `medium` ماڈل استعمال کریں۔ شائع کرنے سے پہلے سب ٹائٹل فائل پڑھیں اور پروڈکٹ کے نام درست کریں۔

10.7 سننے کی چیک لسٹ

مسئلہ	کیا سنائی دیتا ہے	حل
غلط تلفظ	کوئی لفظ غلط لگتا ہے	اسکرپٹ میں تلفظ کے مطابق ہجے بدلیں، صرف وہ پیراگراف دوبارہ بنائیں
Clipping یا تیز چوٹیاں	بلند الفاظ پر کڑکڑاہٹ	گین کم کریں یا -16 LUFS پر دوبارہ normalize کریں، true peak -1 dBTP سے نیچے
روبوٹک لے	ہر جملے کا لہجہ ایک جیسا	جملے چھوٹے کریں، قدرتی وقفے ڈالیں، دوسری آواز آزمائیں
جوڑوں پر کلک	کلپس کے درمیان چھوٹی آواز	ایڈیٹر میں ہر جوڑ پر 10 تا 20 ms کا crossfade ڈالیں
پس منظر کی گونج	بولنے کے دوران مسلسل شور	صفائی کا plug-in استعمال کریں یا دوبارہ بنائیں؛ اپنی آواز کی شور والی ریکارڈنگ بغیر صفائی کے نہ استعمال کریں

مشورہ

ہر وائس اوور کو لیپ ٹاپ کے اسپیکر اور ایئر فون دونوں پر پوری سنیں۔ جو بیانیہ ایک پر ٹھیک لگے، وہ دوسرے پر غیر واضح ہو سکتا ہے۔

باب 11

ویڈیو سازی: بجٹ میں کیا ممکن ہے

11.1 ایماندارانہ توقعات

AI ویڈیو سازی تیزی سے بہتر ہوئی ہے، مگر اب بھی سست اور وسائل کی بھوکی ہے۔ تقریباً پانچ سیکنڈ کا مختصر کلپ 12 GB کارڈ پر کئی منٹ لے سکتا ہے، اور کمزور ہارڈ ویئر پر اس سے بھی زیادہ۔ نتائج جھلملا سکتے ہیں، بہہ سکتے ہیں، اور ہاتھوں اور چہروں کو بگاڑ سکتے ہیں۔ تخلیق شدہ کلپس بہترین طور پر **B-roll** (معاون شاٹس) کے طور پر استعمال ہوتے ہیں، جو چند سیکنڈ کے ہوں، نہ کہ کسی لمبی ویڈیو کی ریڑھ کی ہڈی۔

11.2 تخلیق کی اقسام

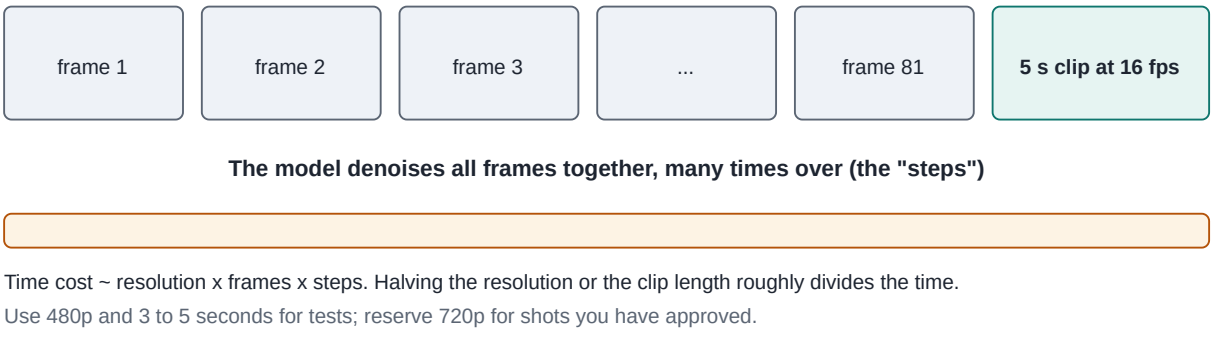
- **متن سے ویڈیو:** تفصیل لکھیں، کلپ حاصل کریں۔ سب سے لچکدار، سب سے کم قابو۔
- **تصویر سے ویڈیو:** ایک تصویر سے شروع کریں جو آپ نے بنائی یا جس کے آپ مالک ہیں، اور اسے متحرک کریں۔ زیادہ قابو؛ جب مخصوص انداز چاہیے تو یہ استعمال کریں۔
- **ویڈیو سے ویڈیو:** موجودہ کلپ کا انداز بدلیں۔ چونکہ یہ کسی اور کی فوٹیج سے شروع ہوتا ہے، اس کے لیے حقوق کی سخت جانچ درکار ہے۔

11.3 ماڈل کے اختیارات اور تقریباً ہارڈ ویئر کی ضرورت

ماڈل خاندان (مثالیں)	کم از کم عملی GPU (تقریباً)	بجٹ ہارڈ ویئر پر عام نتیجہ	لائسنس کا نوٹ
Wan 2.1 / 2.2 چھوٹے ورژن (تقریباً 1.3B تا 5B)	8 تا 12 GB، offloading کے ساتھ	کم ریزولیوشن پر مختصر کلپس، ہر ایک کئی منٹ	تجارتی استعمال سے پہلے ماڈل کارڈ دیکھیں
LTX-Video	8 تا 12 GB	تیز مختصر کلپس، معیار پرامپٹ کے مطابق بدلتا ہے	موجودہ شرائط چیک کریں
CogVideoX (2B)	12 GB+ offloading کے ساتھ	مختصر کلپس، درمیانہ معیار	موجودہ شرائط چیک کریں
HunyuanVideo اور دوسرے بڑے ماڈلز	24 GB+ یا کلاؤڈ GPU	بہترین معیار، 12 GB کارڈ پر عملی نہیں	موجودہ شرائط چیک کریں

ماڈلز کے نام، ورژن اور کم از کم میموری تیزی سے بدلتے ہیں۔ کسی لمبے کام سے پہلے ہمیشہ موجودہ ماڈل کارڈ اور اس کی مثالی ترتیبات پڑھیں۔

11.4 ایک مختصر کلپ کیا ہے



شکل 11.1 کلپ کئی فریمز ہیں جو ایک ساتھ بنتے ہیں۔ لاگت ریزولیوشن، فریمز اور steps کے ساتھ بڑھتی ہے۔ (ڈایاگرام کے لیبل انگریزی میں ہیں)

11.5 ایک عملی طریقہ کار

1. **پہلے شاٹ لسٹ بنائیں۔** ہر شاٹ 3 تا 6 سیکنڈ کا ہو، جس میں ایک واضح حرکت ہو۔
2. **پہلے keyframes کی تصاویر بنائیں** (باب 9 کے ماڈل سے) تاکہ حرکت سے پہلے انداز طے ہو جائے۔
3. **ٹیسٹ کے لیے کم ریزولیوشن (480p) پر متحرک کریں۔** کمزور ٹیک فوراً ضائع کریں۔
4. **منظور شدہ ٹیک کو ہدف ریزولیوشن پر دوبارہ رینڈر کریں،** وہی seed رکھ کر۔
5. **ہر کلپ کو فریم بہ فریم جانچیں** ہاتھوں، چہروں، متن اور جھلملاہٹ کے لیے۔ آرٹی فیکٹس والا کلپ ہٹا دیں۔
6. **ترتیبات کا ریکارڈ رکھیں** (ماڈل، steps، seed، ریزولیوشن، لیا گیا وقت) `09_logs/` میں۔

11.6 زیادہ تر چینل ضروریات کے لیے بہتر متبادل

- **لائسنس یافتہ اسٹاک فوٹیج** معتبر لائبریریوں سے، لائسنس فائل میں رکھ کر۔
- **اپنی فوٹیج:** سافٹ ویئر کی اسکرین ریکارڈنگز، اپنے ہارڈ ویئر کے کلوز اپ، فون سے مختصر کلپس۔ یہ ناظرین کے لیے اکثر زیادہ قابلِ اعتماد ہوتی ہیں۔
- **موشن گرافکس:** آپ کے ایڈیٹر میں بنائے گئے متحرک عنوانات، چارٹس اور خاکے (باب 12)، یا 3D کے لیے Blender۔
- **حرکت والی تصاویر:** AI تصویر پر Ken Burns حرکت (آہستہ پین اور زوم) تقریباً بغیر وقت کے۔
- **کلاؤڈ برسٹ:** چند آخری اہم شاٹس کے لیے کلاؤڈ GPU ایک گھنٹے کے لیے کرائے پر لیں۔ کچھ کرنے سے پہلے لاگت کا موازنہ اپنے وقت سے کریں۔

اعلان

یوٹیوب کی پالیسی کے تحت حقیقت سے مشابہ AI سے بنی یا تبدیل شدہ ویڈیو، جو حقیقی واقعات سمجھی جا سکے، کا اعلان ضروری ہے۔ واضح طور پر فرضی یا اسٹائلائزڈ مواد کو بھی ایمانداری سے لیبل کریں۔ ہر اپ لوڈ سے پہلے موجودہ پالیسی کا صفحہ دیکھیں۔

باب 12

ویڈیو ایڈیٹنگ اور آخری ایکسپورٹ

12.1 ایڈیٹر کا انتخاب

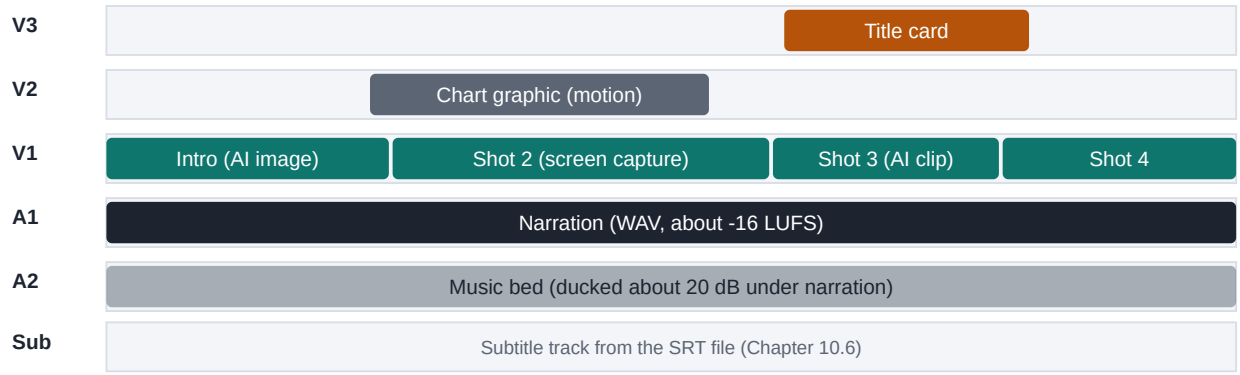
ایڈیٹر	قیمت	پلیٹ فارم	کس کے لیے بہتر
DaVinci Resolve	مفت ورژن بہت قابل ہے؛ Studio ادائیگی والا	Windows، macOS، Linux	پیشہ ورانہ ایڈیٹنگ، رنگ، آڈیو مکسنگ (Fairlight)۔ مجموعی طور پر بہترین انتخاب۔
Kdenlive	مفت، کھلا ماخذ	Linux، Windows، macOS	سادہ، دوستانہ، کمزور مشینوں کے لیے اچھا proxy سپورٹ
Shotcut	مفت، کھلا ماخذ	Windows، macOS، Linux	ہلکا، پرانے ہارڈ ویئر پر کام کرتا ہے
OpenShot	مفت، کھلا ماخذ	Windows، macOS، Linux	بہت سادہ، پہلی ویڈیو کے لیے اچھا
Blender (video sequencer)	مفت، کھلا ماخذ	سب	ایڈیٹس کے ساتھ 3D یا موشن گرافکس ملانا

8 GB یا زیادہ VRAM والی Windows یا Linux مشین کے لیے DaVinci Resolve (مفت) تجویز کردہ انتخاب ہے۔ کمزور لیپ ٹاپ پر، proxies کے ساتھ Kdenlive یا Shotcut بہتر ابتدا ہے۔

12.2 Proxies: کمزور مشین پر ایڈیٹنگ

Proxy ہر کلپ کی چھوٹی، کم ریزولیوشن کاپی ہے جسے ایڈیٹر کاٹتے وقت استعمال کرتا ہے۔ حتمی رینڈر اصل فوٹیج سے ہوتا ہے۔ Proxies کی بدولت 8 GB RAM والا لیپ ٹاپ بھی 4K فوٹیج آسانی سے ایڈٹ کر سکتا ہے۔ Resolve میں Media Pool میں کلپس منتخب کریں، دائیں کلک کریں، اور Generate Proxy Media چنیں (آپ Project Settings میں Proxy Mode بھی لگا سکتے ہیں)۔ Kdenlive میں Project Settings میں proxy clips فعال کریں اور امپورٹ کے وقت transcode کا آپشن استعمال کریں۔

12.3 ٹائم لائن



شکل 12.1 ایک عام ٹائم لائن۔ ویڈیو V1 پر، گرافکس اس کے اوپر، بیانیہ اور موسیقی نیچے، اور سب ٹائٹلز سب سے نیچے۔ (ڈایاگرام کے لیبل انگریزی میں ہیں)

12.4 ایڈیٹنگ کی ترتیب جو وقت بچائے

1. پہلے بیانیہ ٹائم لائن پر رکھیں اور وقفے کاٹیں۔ آواز رفتار طے کرتی ہے۔
2. شاٹس ترتیب سے رکھیں، ہر شاٹ اس جملے سے میل کھاتا ہوا جسے وہ واضح کرتا ہے۔
3. اوپر کے ٹریکس پر گرافکس اور عنوانات ڈالیں۔
4. آخر میں موسیقی کی پرت کم آواز میں ڈالیں، اور تقریر کے نیچے ducking کریں۔
5. سب ٹائٹل فائل درآمد کریں اور ہر سطر کو آڈیو سے ملا کر جانچیں۔
6. پوری ویڈیو ایک بار بغیر رکے دیکھیں۔ ہر مسئلہ نوٹ کریں، پھر ایک ہی بار میں ٹھیک کریں۔

12.5 موسیقی اور آواز

صرف وہ موسیقی استعمال کریں جس کے استعمال کا حق آپ کے پاس ہو: وہ موسیقی جو آپ نے بنائی، رائلٹی فری موسیقی جس کا لائسنس یوٹیوب کی منیٹائزیشن کو کور کرے، یا وہ موسیقی جو ایسے ٹول سے بنی ہو جس کی شرائط تجارتی استعمال کی اجازت دیں۔ لائسنس اور ٹریک کی کاپی rights فولڈر میں رکھیں۔ موسیقی کو تقریر سے 18 تا 22 dB نیچے رکھیں، اور آغاز و اختتام پر ہلکا fade ڈالیں۔

12.6 یوٹیوب کے لیے ایکسپورٹ کی ترتیبات

ترتیب	تجویز کردہ قدر
کنٹینر	MP4
ویڈیو کوڈیک	H.264 (سب سے وسیع مطابقت)؛ H.265 اختیاری ہے

ریزولیوشن اور frame rate	1920 x 1080 پر 30 fps (یا سینما جیسے انداز کے لیے 24 fps)؛ اگر ماخذ سپورٹ کرے تو 4K کے لیے 3840 x 2160
ویڈیو بٹ ریٹ (SDR)	1080p30 کے لیے تقریباً 8 Mbps؛ 1080p60 کے لیے تقریباً 12 Mbps؛ 4K30 کے لیے 35 تا 45 Mbps
آڈیو	AAC، اسٹیریو، 48 kHz، 192 kbps
رنگ	معیاری SDR ویڈیو کے لیے Rec. 709

اپنے ایڈیٹر سے برآمد کریں، یا ایڈیٹر کی master فائل کی صاف حتمی انکوڈنگ کے لیے FFmpeg استعمال کریں:

```
ffmpeg -i final_master.mov -c:v libx264 -preset slow -crf 18 -pix_fmt yuv420p \
  -c:a aac -b:a 192k -ar 48000 -movflags +faststart 07_exports/video_1080p30.mp4
```

NVIDIA کارڈ پر `-c:v h264_nvenc -preset p5 -cq 19` CPU انکوڈر کی جگہ لیتا ہے اور بہت تیز ہے، معیار کے فرق کے ساتھ جو تھوڑا زیادہ ہو سکتا ہے۔

12.7 اپ لوڈ سے پہلے حتمی معیار کی جانچ

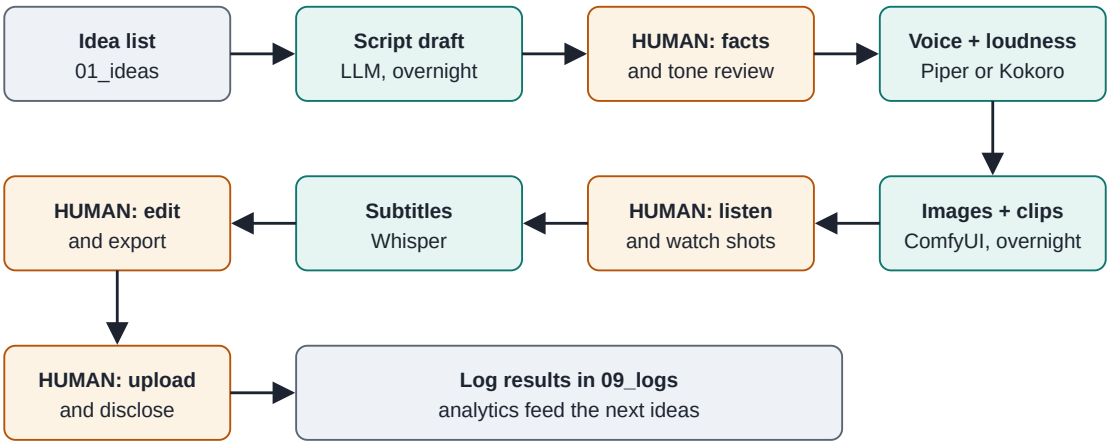
- ایکسپورٹ کو فون اور لیپ ٹاپ دونوں پر چلائیں۔ پہلے پانچ اور آخری دس سیکنڈ خاص طور پر دیکھیں۔
- سب ٹائٹلز، نام اور اعداد اپنی اسکرپٹ سے ملا کر جانچیں۔
- آڈیو لیولز جانچیں: بیانیہ واضح، موسیقی کبھی تقریر سے بلند نہیں، کوئی clipping نہیں۔
- ہر AI سے بنے شاٹ کو آرٹی فیکٹس کے لیے، اور ہر اسٹاک یا موسیقی کے لائسنس کو فائل میں ہونے کے لیے جانچیں۔
- اپ لوڈ فارم میں تبدیل شدہ یا مصنوعی مواد کی اعلان کی ترتیب کی تصدیق کریں۔

باب 13

یوٹیوب پروڈکشن لائن کو خودکار بنانا

13.1 اسے ایک چھوٹی فیکٹری سمجھیں

آٹومیشن کا مطلب انسان کو ہٹانا نہیں۔ اس کا مطلب ہے کہ مشین رات کو دہرائے جانے والے کام کرے، اور ہر اس جگہ انسانی جانچ رکھی جائے جہاں فیصلہ ضروری ہو: حقائق، لہجہ، حقوق، اور آخری اپ لوڈ۔ ایک اچھی ترتیب شدہ لائن ماہانہ زیادہ تیار ویڈیوز دیتی ہے، کم دباؤ کے ساتھ، جبکہ معیار کے فیصلے آپ کے پاس رہتے ہیں۔



Orange boxes are human decisions. Blue-green boxes run unattended. Nothing reaches YouTube without an orange step.

شکل 13.1 رات کی پروڈکشن لائن۔ مشین کے مراحل پس منظر میں چلتے ہیں؛ انسانی مراحل جانچ کے مقامات ہیں۔ (ڈایاگرام کے لیبل انگریزی میں ہیں)

13.2 فولڈر کے نام اور جاب لاگ

ہر ویڈیو کو ایک پروجیکٹ کوڈ دیں، مثلاً `V2611-07` (سال، مہینہ، ترتیب)۔ اس ویڈیو کی ہر فائل اسی کوڈ سے شروع ہو، تاکہ تلاش آسان ہو اور کچھ گڈمڈ نہ ہو۔ `09_logs/jobs.csv` میں ایک سادہ CSV لاگ رکھیں:

```
code,topic,stage,script_ok,voice_ok,visuals_ok,edit_ok,uploaded,notes
V2611-07,Used GPU buying guide,voice_done,no,no,no,no,no,claims in section 3 need checking
```

اسپریڈشیٹ بھی چل سکتی ہے۔ اصول یہ ہے کہ ہر مرحلے کا ایک ذمہ دار ہو (آپ یا مشین) اور ایک تحریری حالت۔

13.3 ایک سادہ پائپ لائن اسکرپٹ

نیچے کا اسکرپٹ ایک موضوع کو اسکرپٹ، وائس اوور اور loudness کے لحاظ سے درست بیانیہ فائل میں بدلتا ہے۔ یہ ایڈیٹنگ سے پہلے رک جاتا ہے، کیونکہ وہ انسانی کام ہے۔ یہ باب 8 کے `scriptwriter` ماڈل اور باب 10 کی Piper آواز پر مبنی ہے۔ اسے `~/homelab/studio/pipeline.py` کے طور پر محفوظ کریں اور پہلے ایک موضوع پر آزمائیں۔

```
import datetime
import pathlib
import subprocess

import ollama

STUDIO = pathlib.Path.home() / "homelab" / "studio"
VOICE = "en_US-lessac-medium.onnx"          # the Piper voice file you downloaded


def make_script(code: str, topic: str) -> pathlib.Path:
    reply = ollama.chat(
        model="scriptwriter",
        messages=[{"role": "user", "content": f"Topic: {topic}. Length: 8 minutes."}],
    )
    path = STUDIO / "02_scripts" / f"{code}_script.md"
    path.write_text(reply["message"]["content"], encoding="utf-8")
    return path


def make_voice(code: str, script_path: pathlib.Path) -> pathlib.Path:
    # Use only the spoken paragraphs: drop lines that start with "[" (section headings)
    lines = [l for l in script_path.read_text(encoding="utf-8").splitlines()
             if l.strip() and not l.startswith("[")]
    text = "\n".join(lines)
    raw = STUDIO / "03_voice" / f"{code}_raw.wav"
    norm = STUDIO / "03_voice" / f"{code}_narration.wav"
    subprocess.run(
        ["piper", "--model", VOICE, "--output_file", str(raw)],
        input=text.encode("utf-8"), check=True,
    )
    subprocess.run(
        ["ffmpeg", "-y", "-i", str(raw), "-af", "loudnorm=I=-16:TP=-1.5:LRA=11",
         "-ar", "48000", str(norm)],
        check=True,
    )
    return norm


def log(message: str) -> None:
    stamp = datetime.datetime.now().isoformat(timespec="seconds")
    with open(STUDIO / "09_logs" / "pipeline.log", "a", encoding="utf-8") as f:
        f.write(f"{stamp} {message}\n")


if __name__ == "__main__":
    code, topic = "V2611-07", "Used GPU buying guide for local AI"
    script = make_script(code, topic)
    log(f"{code} script written: {script.name}")
    narration = make_voice(code, script)
    log(f"{code} narration ready: {narration.name} (human listen required)")
```

اسے رات کے لیے `crontab -e` سے شیڈول کریں، ایک لائن شامل کر کے، مثلاً `0 1 * * * /usr/bin/python3 /home/you/homelab/studio/pipeline.py`۔ پہلے دستی طور پر چلائیں۔ ہر صبح لاگ اور فائلیں چیک کریں۔

> **چلانے سے پہلے کوڈ پڑھیں**
>
> اوپر کا اسکرپٹ ایک تدریسی مثال ہے۔ اسے اپنے فولڈر کی کاپی پر آزمائیں، اور اپنے یوزر نام اور ڈسک کے مطابق راستے چیک کریں۔ کوئی اسکرپٹ بیک اپ کے بغیر مکمل شدہ کام کو حذف یا اوور رائٹ نہ کرے۔

13.4 اختیاری: بصری ورک فلو ٹولز

اگر آپ کمانڈ لکھنے کے بجائے کلک کرنا پسند کریں تو n8n جیسا خود میزبانی والا ورک فلو ٹول وہی مراحل بصری ایڈیٹر کے ذریعے چلا سکتا ہے۔ اسے Docker سے شروع کیا جا سکتا ہے (موجودہ کمانڈ n8n کی دستاویزات سے دیکھیں)، اور یہ Ollama اور ComfyUI کو ان کے مقامی پتوں پر کال کر سکتا ہے۔ ایسے ٹولز کو نجی نیٹ ورک پر رکھیں اور مضبوط پاس ورڈ سے محفوظ کریں۔

13.5 معیار کے دروازے

دروازہ	کون	پاس ہونے کی شرط
اسکرپٹ	انسان	ہر عدد، نام اور دعویٰ تصدیق شدہ ہو؛ ہر [CHECK] ٹیگ حل ہو
آواز	انسان	شروع سے آخر تک سنی گئی ہو؛ تلفظ کی فہرست لاگو ہو؛ loudness ریکارڈ ہو
بصری مواد	انسان	AI شاٹس میں آرٹی فیکٹس نہ ہوں؛ لائسنس فائل میں ہوں؛ بغیر اجازت کسی کی مشابہت نہ ہو
ایڈیٹ	انسان	بغیر رکے ایک بار دیکھی گئی ہو؛ سب ٹائٹلز جانچے گئے ہوں
اپ لوڈ	انسان	عنوان اور تھمب نیل سچے ہوں؛ اعلان کی ترتیب لگی ہو؛ end screen اور cards جانچے گئے ہوں

13.6 مینیٹائز ہونے والے چینل کے لیے پالیسی اور اخلاقیات

- **اصل قدر۔** یوٹیوب کے مینیٹائزیشن قواعد بڑے پیمانے پر یا بار بار دہرائے جانے والے مواد پر پابندی لگاتے ہیں۔ جو چینل صرف مشین کا لکھا متن دوبارہ شائع کرے، جس میں آپ کا کم اضافہ ہو، اسے خطرہ ہے۔ ہر ویڈیو میں اپنی تحقیق، مثالیں، تجربہ اور رائے شامل کریں۔
- **دوسروں کی نقل نہ کریں۔** دوسرے تخلیق کاروں کی ویڈیوز ڈاؤن لوڈ، دوبارہ اپ لوڈ یا قریب سے دوبارہ بیان نہ کریں۔ ڈاؤن لوڈ کرنے والے ٹولز پلیٹ فارم کی شرائط کی خلاف ورزی ہو سکتے ہیں۔ صرف وہی مواد استعمال کریں جس کے حقوق آپ کے پاس ہوں۔
- **مصنوعی میڈیا کا اعلان کریں۔** حقیقت سے مشابہ تبدیل شدہ یا مصنوعی مواد، جہاں ضروری ہو، اپ لوڈ کی ترتیبات میں لیبل ہونا چاہیے۔ ہر ویڈیو بنانے کے طریقے کا ریکارڈ رکھیں۔
- **آوازوں اور چہروں کا احترام۔** لوگوں کی آواز کی نقل یا ان کی تصویر صرف تحریری رضامندی سے۔

- **درستگی پہلے۔** صحت، مالیات اور قانون کے موضوعات پر اضافی جانچ اور واضح بیان ضروری ہے کہ ویڈیو عمومی معلومات ہے۔
- **آؤٹ پٹ کے حقوق۔** ہر ماڈل، فونٹ، موسیقی اور اسٹاک آئٹم کے لائسنس rights فولڈر میں رکھیں، اور ہر ایک کی attribution کی شرائط چیک کریں۔

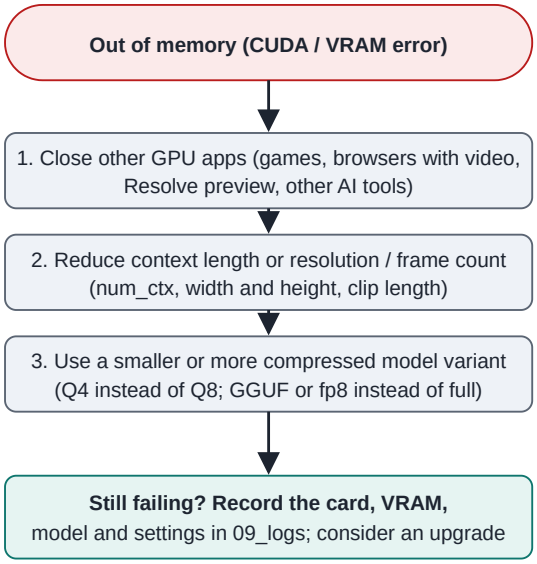
باب 14

ہارڈ ویئر کی حدیں، خرابیوں کا حل اور کارکردگی

14.1 سخت حدیں، ایک جدول میں

حد	کیا ہوتا ہے	عملی جواب
VRAM ماڈل کے لیے بہت چھوٹی	Out-of-memory کی خرابی، یا جزوی CPU استعمال سے بہت سست جواب	چھوٹا ماڈل یا زیادہ کمپریسڈ ورژن چنیں؛ context کم کریں؛ VRAM بڑھائیں
سسٹم RAM بہت چھوٹی	جمنا، ڈسک پر swapping، پروگرام بند ہونا	32 GB تک اپ گریڈ کریں؛ جنریشن کے دوران براؤزر اور ایڈیٹر بند رکھیں؛ swap شامل کریں
Memory bandwidth	رفتار چپ سے نہیں، میموری کے راستے سے محدود ہوتی ہے	GPU میموری استعمال کریں؛ بڑے ماڈلز کے لیے صرف CPU سے بچیں
گرمی اور بجلی	clock کی رفتار گھٹتی ہے (throttling)؛ پنکھے شور کرتے ہیں	گرد صاف کریں، ہوا کا بہاؤ بہتر کریں، power محدود کریں، لیپ ٹاپ کے لیے کولنگ پیڈ
ڈسک کی جگہ اور رفتار	بھری ڈسک ڈاؤن لوڈ روک دیتی ہے؛ سست ڈسک ماڈل لوڈنگ کو سست کرتی ہے	100 GB خالی رکھیں؛ ماڈلز اور پروجیکٹس کے لیے NVMe SSD استعمال کریں
ویڈیو سازی کا وقت	ہر مختصر کلپ کے لیے منٹ	شاٹس کی منصوبہ بندی، کم ریزولیوشن پر ٹیسٹ، رات کو بیچ، دوسری فوٹیج کے ساتھ ملانا
ماڈل کے معیار کی حد	چھوٹے ماڈل زیادہ غلطیاں کرتے ہیں اور زیادہ عام لگتے ہیں	بہتر ہدایات دیں، آؤٹ پٹ جانچیں، مشکل ترین کاموں کے لیے بڑا ماڈل
بجلی کا خرچ	300 W کا لوڈ 2 گھنٹے میں 0.6 kWh استعمال کرتا ہے	بھاری کام شیڈول کریں؛ کم power limit؛ بے کار ہونے پر بند کریں

14.2 جب تخلیق ناکام ہو: ایک فیصلہ بہاؤ



Each step is a deliberate change. Change one thing at a time so you know what fixed it.

شکل 14.1 میموری کی خرابیاں ایک وقت میں ایک قدم سے ٹھیک کریں، اور ہر تبدیلی کا ریکارڈ رکھیں۔ (ڈایاگرام کے لیبل انگریزی میں ہیں)

14.3 خرابیوں کے حل کی جدول

علامت	ممکنہ وجہ	حل
`nvidia-smi` نہیں ملتا (Linux)	ڈرائیور انسٹال نہیں، یا Secure Boot ماڈیول کو روکتا ہے	`sudo ubuntu-drivers install` چلائیں اور ری اسٹارٹ کریں۔ اگر Secure Boot آن ہو تو boot کے وقت نیلی MOK اسکرین پر signing key enroll کریں، یا BIOS میں Secure Boot بند کریں
`nvidia-smi` نہیں ملتا (WSL2)	پرانا Windows ڈرائیور یا پرانا WSL	Windows پر NVIDIA ڈرائیور اپ ڈیٹ کریں؛ `wsl --update` چلائیں، پھر `wsl --shutdown` کریں اور Ubuntu دوبارہ کھولیں
Ollama صرف CPU استعمال کرتا ہے	GPU نہیں ملا، یا VRAM بہت کم	`nvidia-smi` چیک کریں؛ `ollama ps` چیک کریں؛ چھوٹا ماڈل چنیں
کچھ دیر بعد جوابات بہت سست	Thermal throttling یا power limit	`nvidia-smi` میں درجہ حرارت اور clocks دیکھیں؛ پنکھے صاف کریں؛ ہوا کا بہاؤ بہتر کریں
Open WebUI ماڈلز نہیں دیکھ پاتا	Docker، Ollama تک نہیں پہنچ پاتا	باب 6 کا `--add-host` آپشن استعمال کریں؛ چیک کریں کہ Ollama درست پتے پر سن رہا ہے
پورٹ پہلے سے استعمال میں ہے	کوئی اور پروگرام (اکثر LM Studio) اسے استعمال کر رہا ہے	دونوں میں سے ایک بند کریں، یا اس کا پورٹ بدلیں

ڈاؤن لوڈ کے دوران ڈسک بھر گئی	ماڈلز جمع ہو گئے	`ollama list` سے دیکھیں، `ollama rm` سے ہٹائیں؛ `OLLAMA_MODELS` سے ماڈلز کسی اور ڈسک پر منتقل کریں
بڑے کاموں پر مشین جم جاتی ہے	RAM ختم	ایپس بند کریں؛ swap شامل کریں؛ بیچ کا سائز کم کریں؛ RAM اپ گریڈ کریں
ویڈیو آؤٹ پٹ جھلملاتا یا بگڑتا ہے	ماڈل کی حد یا مواد کے لیے بہت زیادہ steps	چھوٹے شاٹس، سادہ حرکت، keyframe پر مبنی تصویر سے ویڈیو، پیچیدہ شاٹس کے لیے لائسنس یافتہ فوٹیج
وائس کلپس جوڑوں پر کٹ جاتے ہیں	Piper یا TTS نے جملہ توڑ دیا	متن کو فل اسٹاپ پر تقسیم کریں؛ ایڈیٹر میں چھوٹے crossfades ڈالیں

14.4 کارکردگی کی ترتیبات جو جاننا مفید ہیں

Ollama چند environment variables پڑھتا ہے۔ Ubuntu پر انہیں سروس میں `sudo systemctl edit ollama` سے شامل کریں، پھر `[Service]` سرخی کے نیچے لکھیں، محفوظ کریں، اور `sudo systemctl restart ollama` چلائیں:

```
[Service]
Environment="OLLAMA_KEEP_ALIVE=10m"          # keep a model loaded 10 minutes after use
Environment="OLLAMA_MAX_LOADED_MODELS=1"     # one model in memory at a time: fewer
surprises
Environment="OLLAMA_NUM_PARALLEL=1"          # one request at a time: fastest single
answers
Environment="OLLAMA_FLASH_ATTENTION=1"       # faster attention on supported cards
Environment="OLLAMA_MODELS=/mnt/models/ollama"   # optional: store models on another disk
```

> **نجی رکھیں**
>
> Ollama ڈیفالٹ میں صرف اسی مشین پر سنتا ہے۔ `OLLAMA_HOST=0.0.0.0` اسے پورے نیٹ ورک سے قابلِ رسائی بنا دیتا ہے۔ یہ صرف فائر وال کے پیچھے کریں، اور اسے کبھی بھی راؤٹر کے ذریعے انٹرنیٹ پر نہ کھولیں۔

14.5 NVIDIA پر بجلی اور گرمی کم کرنا

آپ کارڈ کی بجلی محدود کر سکتے ہیں تاکہ گرمی اور شور کم ہو، رفتار میں تھوڑے نقصان کے ساتھ۔ پہلے اجازت شدہ حد دیکھیں:

```
nvidia-smi -q -d POWER | grep -i "power limit"
sudo nvidia-smi -pl 150          # sets a 150 W limit (example for an RTX 3060-class card)
```

یہ ترتیب ری بوٹ پر ختم ہو جاتی ہے۔ پہلے اور بعد میں کچھ کام چلا کر وقت اور درجہ حرارت کا تبادلہ ناپیں۔ دونوں کو اپنے لاگ میں لکھیں۔

14.6 آپ کے پاس جو ہے اسے ناپنا

پیمانہ	ٹول	اچھا نتیجہ
Tokens فی سیکنڈ	`ollama run model --verbose` (eval rate دکھاتا ہے)	7B ماڈل: اچھے 12 GB کارڈ پر 30 tok/s سے زیادہ؛ 14B: 15 tok/s سے زیادہ
استعمال میں GPU میموری	`nvidia-smi`	کل VRAM سے کم، 1 تا 2 GB خالی
GPU کا درجہ حرارت	`nvidia-smi`	لوڈ کے تحت تقریباً 83 ڈگری سیلسیئس سے کم
ماڈل کی جگہ	`ollama ps`	وہ ماڈل جو آپ سب سے زیادہ استعمال کرتے ہیں، "100% GPU"
ویڈیو رینڈر کا وقت	آپ کا اپنا لاگ	مہینوں میں رجحان بگڑنا نہ چاہیے (گرد کا جمع ہونا یہاں سب سے پہلے دکھتا ہے)

یہ اعداد تخمینی رہنمائی ہیں، ضمانت نہیں۔ آپ کے کام کے لیے صرف آپ کا اپنا لاگ اہم ہے۔

14.7 کب اپ گریڈ کریں، اور پہلے کیا خریدیں

1. **پہلے RAM** اگر جمنا یا swapping نظر آئے، اور یہ سستی ہے۔
2. **دوسرے نمبر پر ڈسک** اگر جگہ کم ہو: 1 TB NVMe ڈرائیو زیادہ تر مسائل حل کرتی ہے۔
3. **تیسرے نمبر پر VRAM**، جب مسلسل وہ ماڈل یا سائز درکار ہو جو نہیں سماتا۔ یہ سب سے مہنگا اپ گریڈ ہے اور اس کا اثر سب سے بڑا ہے۔
4. **کلاؤڈ GPU** کبھی کبھار کے بھاری کاموں کے لیے، اگر آپ کا ماہانہ حجم اپ گریڈ کا جواز نہ دے۔

باب 15

کیریئر کا راستہ، بجٹ کا منصوبہ اور 12 ہفتے کا مطالعاتی منصوبہ

15.1 حقیقت پسندانہ کیریئر کے راستے

مقامی AI اسٹوڈیو آمدنی کی خودکار ضمانت نہیں، بلکہ مہارت کی بنیاد ہے۔ جو لوگ اس سے کماتے ہیں وہ ٹولز کو ایڈیٹنگ کی سمجھ، کہانی سنانے کی صلاحیت اور قابلِ اعتماد ڈیلیوری کے ساتھ ملاتے ہیں۔ عام راستے یہ ہیں:

- **چہرے کے بغیر یا جزوی طور پر بغیر چہرے والے چینل کا پروڈیوسر:** آپ ایک واضح نیچ (niche) کے ساتھ اپنا چینل بناتے اور چلاتے ہیں۔
- **فری لانس ویڈیو ایڈیٹر** تخلیق کاروں اور چھوٹے کاروباروں کے لیے، جو ڈرافٹس، سب ٹائٹلز اور وائس اوور کے لیے AI ٹولز استعمال کرتا ہے۔
- **وضاحتی ویڈیو کا پروڈیوسر** کمپنیوں، اسکولوں اور غیر منافع بخش اداروں کے لیے۔
- **تھمب نیل، گرافک اور آڈیو صفائی کی خدمات** دوسرے تخلیق کاروں کے لیے۔
- **کری ایٹر آٹومیشن اسپیشلسٹ:** چھوٹی ٹیموں کے لیے محفوظ پروڈکشن لائنیں بنانا۔

پلیٹ فارم سے آمدنی غیر یقینی ہے۔ یوٹیوب پارٹنر پروگرام کے لیے کم از کم سب اسکرائبر اور واچ ٹائم کی حدیں ہیں، اور یہ بدلتی ہیں، اس لیے منصوبہ بنانے سے پہلے موجودہ شرائط دیکھیں۔ زیادہ تر چینلز کو بڑھنے میں کئی مہینے لگتے ہیں۔ فری لانس اور سروس کی آمدنی اکثر زیادہ قابلِ پیش گوئی ہوتی ہے، اور وہ چینل کو سہارا دے سکتی ہے۔

15.2 ٹولز کے ساتھ ساتھ بنانے والی مہارتیں

مہارت	یہ کیوں کماتی ہے	مشق کیسے کریں
کہانی سنانا اور اسکرپٹ نویسی	ناظرین کہانی کے لیے رکتے ہیں، ٹول کے لیے نہیں	ہر ہفتے ایک اسکرپٹ لکھیں اور اسے اپنی بہترین کارکردگی والی ویڈیو سے موازنہ کریں
ایڈیٹنگ کی لے اور آواز	اچھی آواز اوسط بصری مواد کو بھی دیکھنے کے قابل بناتی ہے	ہر ماہ ایک پرانی ویڈیو کو زیادہ سخت رفتار سے دوبارہ ایڈٹ کریں
تھمب نیل اور عنوان کا ڈیزائن	کلک ریٹ ان پر بہت منحصر ہے	ہر ویڈیو کے تین تھمب نیل ویرینٹس بنائیں اور نتائج کا ایمانداری سے موازنہ کریں
Analytics پڑھنا	بتاتا ہے کہ اگلا کیا بنانا ہے	ہفتہ وار retention گراف دیکھیں اور ہر ویڈیو کا ایک سبق لکھیں

بنیادی Python اور کمانڈ لائن	بار بار کے کاموں کو خودکار بناتا ہے	ہر ماہ ایک چھوٹا کام خودکار کریں
حقوق اور اعلان	آمدنی اور ساکھ کی حفاظت کرتا ہے	حقوق کا فولڈر اور چینل کے لیے ایک صفحے کی پالیسی رکھیں

15.3 بجٹ کا منصوبہ: چار درجے

اخراجات آپ کے ملک اور استعمال شدہ مارکیٹ پر منحصر ہیں۔ نیچے کی سطحیں مقابلتاً خرچ بتاتی ہیں۔ خریدنے سے پہلے موجودہ قیمتیں دیکھیں۔

درجہ	کیا خریدیں	تقابلی لاگت	کیا کھلتا ہے
A. آغاز	کچھ نیا نہیں۔ اپنی موجودہ مشین پر Ubuntu یا Windows؛ مفت ٹولز (Ollama، Open WebUI، Kdenlive یا Resolve، FFmpeg، Piper)	مفت، بجلی کے علاوہ	باب 5 تا 10 اور بنیادی ایڈیٹنگ۔ چھوٹے ماڈلز، وائس اوور، اسکرپٹس
B. RAM اور اسٹوریج شامل کریں	RAM کو 32 GB تک؛ 1 TB NVMe SSD؛ surge protector	کم	بڑے ماڈلز، ہموار ایڈیٹنگ، پروجیکٹس کے لیے زیادہ جگہ
C. استعمال شدہ 12 GB GPU شامل کریں	12 GB VRAM والا استعمال شدہ NVIDIA کارڈ؛ ضرورت ہو تو معیاری پاور سپلائی	درمیانی	14B ماڈلز، جدید تصویری ماڈلز، مختصر ویڈیو ٹیسٹ، Full-HD پروڈکشن
D. 24 GB GPU شامل کریں	استعمال شدہ 24 GB کارڈ اور مناسب کیس اور پاور سپلائی	زیادہ	بڑے ماڈلز، تیز تصویر اور ویڈیو کام، 4K ایڈیٹنگ

عام اصول: اس مہارت کے لیے ہارڈ ویئر نہ خریدیں جس کی آپ نے ابھی مشق نہیں کی۔ درجہ A کو کم از کم ایک مہینہ مکمل کریں، دیکھیں کون سا کام سب سے سست ہے، اور پھر صرف وہ حصہ خریدیں جو اس رکاوٹ کو ہٹائے۔

15.4 چلانے کے اخراجات

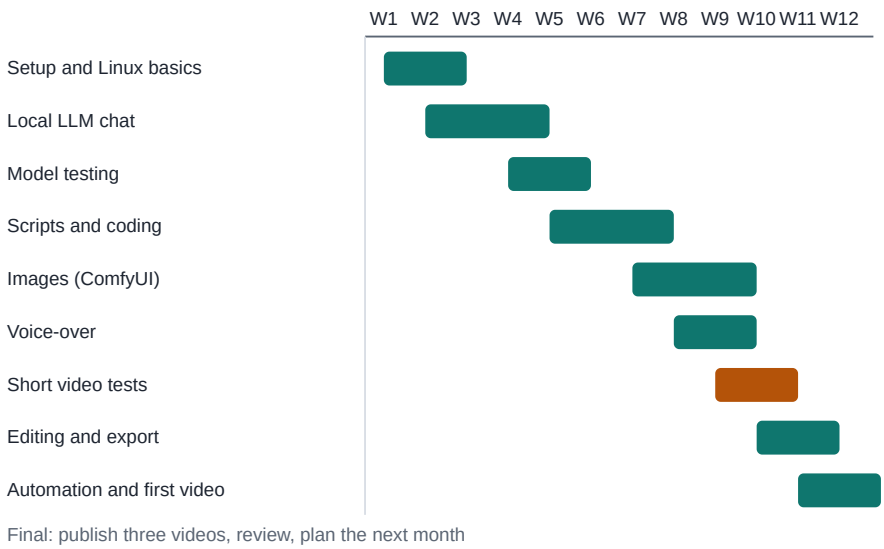
```
electricity per hour (kWh) = power draw (W) ÷ 1000
cost per session           = kWh × your price per kWh

Example: 300 W for 2 hours = 0.6 kWh.
At an electricity price of 0.20 per kWh, that is 0.12 per session.
Idle at 60 W for 24 hours = 1.44 kWh per day.
```

بھاری کام فی گھنٹہ سستے ہیں، مگر مہینے بھر میں جمع ہو جاتے ہیں۔ لمبے بیچ رات کو چلائیں جب آپ مشین استعمال نہیں کر رہے، اور بے کار ہونے پر مشین بند کریں یا sleep میں رکھیں۔

15.5 12 ہفتے کا مطالعاتی منصوبہ

یہ منصوبہ ہفتے میں تقریباً 6 تا 8 گھنٹے فرض کرتا ہے۔ ہر ہفتہ ایک ایسے نتیجے پر ختم ہوتا ہے جسے آپ جانچ سکیں۔



شکل 15.1 مطالعاتی ٹائم لائن۔ ہر بار ایک مہارت کا بلاک ہے؛ نارنجی بار سب سے مشکل مرحلہ ہے، جہاں زیادہ تر سیکھنے والوں کو اضافی وقت چاہیے۔ (ڈایاگرام کے لیبل انگریزی میں ہیں)

ہفتہ	توجہ	نتیجہ (آگے بڑھنے سے پہلے جانچیں)
1	آپریٹنگ سسٹم، ڈرائیورز، فولڈرز، نگرانی کے ٹولز	`nvidia-smi` کام کرے؛ فولڈر ڈھانچہ موجود ہو؛ بیس لائن لاگ ہو
2	Ollama اور Open WebUI؛ پہلی چیٹ؛ `ollama ps`	اپنے موضوع پر پانچ جواب؛ ماڈل GPU پر
3	اپنے ٹیسٹ سیٹ سے ماڈل کا موازنہ (باب 7)	تین ماڈلز کا اسکور شدہ جدول؛ وجوہات کے ساتھ ایک چنا گیا
4	اسکرپٹس: scriptwriter ماڈل، پرامپٹ کے ڈھانچے، بیچ اسکرپٹ	تین خاکے اور ایک مکمل اسکرپٹ جس کے [CHECK] ٹیگ حل ہوں
5	ComfyUI، پہلی تصاویر، پرامپٹ لاگ	دس تصاویر، لاگ کے ساتھ؛ ایک تھمب نیل کا پس منظر
6	تصویری ترتیبات، 1280 x 720 پر تھمب نیل	تین مکمل تھمب نیل ویرینٹس کا موازنہ
7	آواز: Piper یا Kokoro، loudness، تلفظ کی فہرست	ایک منظور شدہ بیانیہ، تقریباً -16 LUFS پر
8	Whisper سے سب ٹائٹلز؛ آواز کی QA چیک لسٹ	آپ کی بیانیہ کے لیے درست SRT فائل
9	480p پر مختصر AI ویڈیو ٹیسٹ	تین ٹیسٹ کلپس، لیا گیا وقت اور آرٹی فیکٹس نوٹ شدہ
10	ایڈیٹنگ: proxies، ٹائم لائن، موسیقی کا ducking	ایک 2 منٹ کی ایڈٹ شدہ ترتیب
11	آٹومیشن: پائپ لائن اسکرپٹ، جاب لاگ، معیار کے دروازے	ایک موضوع شروع سے آخر تک، انسانی جانچ کے مقامات کے ساتھ

12	مکمل ویڈیو: اسکرپٹ سے ایکسپورٹ تک، جانچ، اعلان کے ساتھ اپ لوڈ	ایک مکمل شائع شدہ ویڈیو اور تبدیلیوں کا تحریری جائزہ

آخری مشورہ

اس کورس کا سب سے قیمتی نتیجہ ویڈیوز نہیں، آپ کا لاگ ہے: آپ نے کیا آزمایا، اس کی وقت اور بجلی میں کیا لاگت آئی، اور ناظرین نے کس چیز پر ردعمل دیا۔ اسے ایمانداری سے رکھیں، اور آپ کی اگلی خریداری درست ہوگی۔

ضمیمہ A

کمانڈ کی فہرست

مقصد	کمانڈ
GPU، VRAM اور درجہ حرارت دیکھیں	`nvidia-smi` (یا `watch -n 1 nvidia-smi`)
تجویز کردہ NVIDIA ڈرائیور انسٹال کریں (Ubuntu)	`sudo ubuntu-drivers install`
RAM اور swap دیکھیں	`free -h`
ڈسک کی جگہ دیکھیں	`df -h ~`
سب سے بڑے فولڈرز تلاش کریں	`du -sh ~/* | sort -h`
ماڈل ڈاؤن لوڈ کریں	`ollama pull qwen2.5:7b`
ٹرمینل میں چیٹ کریں	`ollama run qwen2.5:7b`
انسٹال ماڈلز کی فہرست	`ollama list`
لوڈ شدہ ماڈلز اور ان کی جگہ دیکھیں	`ollama ps`
ماڈل ہٹائیں	`ollama rm model-name`
Modelfile سے مخصوص ماڈل بنائیں	`ollama create scriptwriter -f Modelfile`
چیٹ میں context مقرر کریں	`/set parameter num_ctx 8192`
Ollama دوبارہ شروع کریں (Linux)	`sudo systemctl restart ollama`
Open WebUI شروع کریں	`docker start open-webui`
ComfyUI شروع کریں	`cd ~/homelab/ComfyUI && source .venv/bin/activate && python main.py`
آواز بنائیں	`echo "text" | piper --model voice.onnx --output_file out.wav`
Loudness normalize کریں	`ffmpeg -i in.wav -af loudnorm=I=-16:TP=-1.5:LRA=11 -ar 48000 out.wav`
حتمی MP4 انکوڈ (CPU)	`ffmpeg -i master.mov -c:v libx264 -preset slow -crf 18 -c:a aac -b:a 192k -movflags +faststart out.mp4`

حتمی MP4 انکوڈ (NVIDIA)	`ffmpeg -i master.mov -c:v h264_nvenc -preset p5 -cq 19 -c:a aac -b:a 192k out.mp4`
GPU power limit مقرر کریں (NVIDIA، ری بوٹ پر ختم)	`sudo nvidia-smi -pl 150`

ضمیمہ B

اصطلاحات کی فرہنگ

اصطلاح	مطلب
Checkpoint	تصویری تخلیق کے لیے محفوظ ماڈل فائل (وزن)۔
Context	وہ متن کی مقدار جو لینگوئج ماڈل ایک وقت میں مدنظر رکھ سکتا ہے، tokens میں ناپی جاتی ہے۔
CUDA	NVIDIA کی سافٹ ویئر پرت جو پروگراموں کو GPU استعمال کرنے دیتی ہے۔ زیادہ تر ٹولز کے لیے ڈرائیور کے ساتھ انسٹال ہوتی ہے۔
Diffusion	زیادہ تر تصویری اور ویڈیو ماڈلز کا طریقہ: شور سے شروع کر کے قدم بہ قدم بہتر کرنا۔
Docker	ایک ٹول جو پروگراموں کو containers نامی الگ تھلگ پیکجوں میں چلاتا ہے۔
Fine-tuning اور LoRA	اپنی مثالوں پر ایک چھوٹا add-on تربیت دینا تاکہ ماڈل کا انداز بدلے۔ زیادہ ہارڈ ویئر اور احتیاط درکار۔
FFmpeg	میڈیا کو بدلنے، سکیل کرنے، جوڑنے اور انکوڈ کرنے کے لیے مفت کمانڈ لائن ٹول۔
GPU، VRAM	گرافکس پروسیسر، اور اس کی مخصوص میموری۔ VRAM AI کے کام کی سب سے اہم حد ہے۔
Inference	تربیت یافتہ ماڈل کو جواب یا آؤٹ پٹ کے لیے چلانا۔ آپ کا ہوم لیب یہی کرتا ہے۔
LUFS	Loudness Units relative to Full Scale؛ محسوس ہونے والی بلندی ناپنے کا معیاری پیمانہ۔
LLM	Large language model: وہ ماڈل جو متن بناتا اور سمجھتا ہے۔
Parameters	ماڈل کے سیکھے ہوئے عدد۔ "7B" کا مطلب سات ارب۔
Proxy	کم ریزولیوشن کی فوٹیج کی کاپی، جو کمزور مشینوں پر ہموار ایڈیٹنگ کے لیے استعمال ہوتی ہے۔
Quantization	ماڈل کے وزن کو کم بٹس میں محفوظ کرنا تاکہ سائز اور میموری کم ہو، کچھ معیار کی قیمت پر۔
Reasoning model	وہ ماڈل جو حتمی جواب سے پہلے اندرونی قدم بہ قدم سوچ لکھتا ہے۔
Seed	وہ عدد جو بے ترتیبی کو کنٹرول کرتا ہے۔ وہی seed اور ترتیبیں وہی نتیجہ دیتی ہیں۔
Swap	RAM ختم ہونے پر ڈسک کی سست اضافی میموری کے طور پر استعمال۔
Throttling	زیادہ گرمی یا power حد سے بچنے کے لیے پروسیسر کی خودکار سست روی۔
Token	متن کا ایک ٹکڑا، اکثر ایک لفظ یا لفظ کا حصہ، جسے ماڈل پڑھتا یا لکھتا ہے۔
TTS / STT	Text-to-speech (آواز بنانا) اور speech-to-text (ٹرانسکرپشن)۔
WSL2	Windows Subsystem for Linux، ورژن 2: Windows کے اندر حقیقی Linux کرنل۔

ضمیمہ C

لائسنس کا مختصر حوالہ

یہ رہنمائی ایک نقطۂ آغاز ہے، قانونی مشورہ نہیں۔ شائع کرنے سے پہلے ہمیشہ مکمل لائسنس اور ماڈل کارڈ پڑھیں۔

لائسنس کی قسم	تجارتی استعمال	عام شرائط	مثالیں (تصدیق کریں)
Apache 2.0	ہاں	نوٹس برقرار رکھیں؛ ترمیم کریں تو تبدیلیاں بتائیں	کئی نئے ماڈلز اور ٹولز
MIT	ہاں	کاپی رائٹ نوٹس برقرار رکھیں	کئی لائبریریاں اور کچھ آواز کے ٹولز
OpenRAIL خاندان	عموماً ہاں	نقصان دہ یا گمراہ کن استعمال پر پابندیاں لاگو	Stable Diffusion خاندان کے ویرینٹس
کمیونٹی یا مخصوص لائسنس	اکثر ہاں، حدود کے ساتھ	آمدنی کی حدیں، attribution، قابلِ قبول استعمال کے اصول	کچھ تصویری اور آڈیو ماڈلز
غیر تجارتی (CC BY-NC یا مشابہ)	نہیں	صرف سیکھنے، جانچ اور ذاتی استعمال کے لیے	کچھ اعلیٰ معیار کے تصویری اور آواز کے ماڈلز
صرف تحقیق کے لیے	نہیں	صرف تحقیقی استعمال	کچھ تجرباتی ویڈیو اور آواز کی cloning کے ماڈلز

ہر ریلیز سے پہلے

ہر پروجیکٹ فولڈر میں `rights.txt` نامی فائل رکھیں۔ شائع شدہ ویڈیو میں استعمال ہونے والے ہر ماڈل، آواز، فونٹ، تصویر اور موسیقی کے لیے اس کا نام، ورژن، لائسنس اور چیک کرنے کی تاریخ درج کریں۔